PŘÍRODOVĚDECKÁ FAKULTA UNIVERZITY PALACKÉHO KATEDRA INFORMATIKY

BAKALÁŘSKÁ PRÁCE

Implementace expertního systému s dopředným řetězením Forward-chaining Expert System Implementation



2010 Jakub Kaláb



Anotace

Expertní systémy mají v praxi bohaté využití. Jejich smyslem je asistovat expertovi na danou problematiku, či jej plně nahradit. V příloze bakalářské práce implementuji prázdný expertní systém s dopředným řetězením inspirovaný systémem CLIPS jako knihovnu v programovacím jazyku Common Lisp tak, aby jej bylo možno plně integrovat do dalších programů.



Obsah

1.	Co	je to experní systém	1	
	1.1.	Co odlišuje expertní systém od jiných výpočetních programů	1	
		Charakteristické vlastnosti expertních systémů	1	
2.	Uživatelská příručka 2			
	2.1.	Použité datové struktury	2	
	2.2.	Manipulace s fakty znalostní baze	3	
		2.2.1. Definice skupiny faktů	3	
	2.3.	Manipulace s odvozovacími pravidly	4	
	2.4.	Spouštění inferenčního mechanismu	4	
		2.4.1. Strategie výběru pravidla k aktivaci	5	
	2.5.	Sledování změn prostředí	5	
	2.6.	Příklad práce s knihovnou	5	
3.	Použité algoritmy 8			
	3.1.	Algoritmus Rete	8	
		3.1.1. Alfa síť	8	
		3.1.2. Beta síť	10	
		3.1.3. Přidání/odebrání inferenčních pravidel	11	
	3.2.	Strategie pro výběr pravidla k aktivaci	12	
4.	Popis implementace 13			
	4.1.	Templates	14	
	4.2.	Facts a Patterns	14	
	4.3.	Rules	14	
	4.4.	Rete	14	
	4.5.	Matches	16	
	4.6.	Activations	16	
5.	Stra	Strategies 16		
		Environment	16	
Reference 17			17	

1. Co je to experní systém

Expertní systém je počítačový program, který ze zadané znalostní báze pomocí zadaných pravidel odvozuje nová fakta. Díky tomu je jej možno využít v praxi jako asistenta odborníka v daném oboru, nebo jej, v ideálním případě, zcela nahradit.

Pro lepší představu uvedu příklad - expertní systém v ordinaci praktického lékaře. Na začátku zadá lékař, případně za pomoci znalostního inženýra, expertnímu systému znalostní bazi, tj. informace o příznacích známých chorob, možnostech jejich léčby, medikaci, konfliktních léků, atd. Expertní systém potom při zadání příznaků pacienta s jistou pravděpodobností (odvislé od pravděpodobností zadaných v jednotlivých pravidlech příznak \rightarrow choroba) určí možné choroby, alternativy léčby, apod.

1.1. Co odlišuje expertní systém od jiných výpočetních programů

Toto samozrejmě může dělat i program, který bychom za expertní systém neoznačili, rozdíl je v tom, že expertní systém je obecný - znalostní baze je zcela oddělena řídícího mechanismu. Tento je tudíž zcela nezávislý na konkrétní doméně. Takto tomu u jiných programů většinou nebývá, data bývají smýchána s rozhodovacím a řídícím kódem programu a program je tudíž jednoúčelový.

1.2. Charakteristické vlastnosti expertních systémů

2. Uživatelská příručka

Tato práce se zabývá implementací již známých algoritmů, je tedy spíše praktického zaměření. Úmyslně jsem tedy posunul kapitolu s hlubším popisem implementovaných algoritmů až za uživatelskou příručku, aby byl čternář při její četbě již seznámen s používanými datovými strukturami, strukturou pravidel, apod.

Tato kapitola vyžaduje alespoň zběžnou znalost programovacího jazyka Common Lisp, jeho základních datových typů (symbol, seznam) a metod pro práci s nimi.

V kapitole budu občas uvádět v závorkách a kurzívou názvy některých použitých tříd či metod. Je to kvůli snadnější orientaci při následné četbě programátorské dokumentace. Čtenář, který tuto číst nehodlá je může směle přeskakovat.

2.1. Použité datové struktury

Uživatel knihovny Exil (dále jen knihovny) se nejčasteji setká se dvěma datovými strukturami, jsou to fakta (třída fact) a pravidla (třída rule). Fakta znalostní baze mohou být buď jednoduchá (třída simple-fact), specifikovaná prostým seznamem atomů (např. (on book table)), či strukturovaná (třída template-fact. Pro použití strukturovaných fakt je třeba nejdříve definovat šablonu makrem deftemplate následovně:

```
(deftemplate in (object location (ammount :default 1)))
```

Volání makra je velice podobné volání vestavěného makra Common lispu defclass, jen neobsahuje seznam tříd, neboť neposkytuje dědičnost. Prvním parametrem je jméno šablony, dalším pak seznam slotů (pojmenované části faktu) s případnými implicitními hodnotami. Specifikace takovéhoto strukturovaného faktu pak vypadá takto: (in :object fridge :location kitchen).

Pozn.: Při opakovaném volání deftemplate se stejným jménem šablony dochází k přepsání původní definice. Má-li nově definovaná šablona jiné sloty než šablona původní a existují-li ve znalostní bazi fakta vytvořená pomocí původní šablony, vzniká nekonzistence. Makro je tedy třeba volat s rozmyslem.

Kromě fakt se uživatel setká ještě s tzv. patterny (pro neznalost výstižného českého ekvivalentu se budu držet dobře zažitého výrazu anglického). Tyto jsou faktům velmi podobné, jen se v nich mohou vyskytovat proměnné. Název proměnné v mé implementaci vždy začíná otazníkem (stejně jako v systému CLIPS) a je tedy od běžného atomu jasně patrný. Patterny mohou být, stejně jako fakta, jednoduché či strukturované. Při snaze použít proměnnou v popisu faktu skončí vyhodnocení výrazu chybou.

Odvozovací pravidlo je druhým stavebním kamenem expertního systému. Umožňuje inferenčnímu mechanismu vyvozovat ze zadaných fakt fakta nová. Pravidlo sestává ze dvou částí - podmínkek a aktivací. Podmínky určují, za jakých

okolností je pravidlo splněno fakty znalostní baze a je jej možno zařadit do seznamu pravidel k aktivaci (tento seznam budu dále označovat jako agenda). Seznam aktivací je tvořen libovolným počtem lispových výrazů (jež pochopitelně mohou, a velmi často budou, zahrnovat i knihovnou definované metody a makra), které se při aktivaci pravidla vyhodnotí. Pravidlo tedy typicky při platnosti nějakých fakt či neplatnosti jiných přidá do znalostní baze nějaká další fakta, či některerá z baze odebere.

2.2. Manipulace s fakty znalostní baze

K přidání faktu do znalostní baze souží makro assert, přidání tedy vypadá následovně:

```
(assert (on book table))
(assert (in :object fridge :location kitchen))
```

Při pokusu o opětované přidání již existujícího faktu se nestane nic.

Odebrání faktu z baze se provádí makrem retract se stejnou syntaxí. Při pokusu o odebrání neexistujícího faktu se opět nic nestane.

Posledním makrem z této skupiny je modify to slouží k modifikaci faktu (jeho nahrazení jiným) a používá se takto:

Toto makro je ve skutečnosti jen zkratkou pro postupné volání assert a retract. Neslouží ani tak k ušetření zdrojového kódu, jako spíš ke zčitelnění aktivací pravidla - z jeho použití je evidentní vztah dvou faktů.

2.2.1. Definice skupiny faktů

Pro pohodlnější práci s větším množstvím faktů jsem (stejně jako systém CLIPS) implementoval makro deffacts. Volání tohoto makra obsahuje název skupiny faktů náledovaný jejich seznamem:

```
(deffacts stuff-i-ve-got-in-me-fridge
  (in :object coke :location fridge)
  (in :object cheese :location fridge)
  (is-expired cheese)
  (in :object butter :location fridge)
    ...
)
```

Takto definovaná fakta se ve znalostní bazi neobjeví hned, nýbrž až po zavolání makra reset (bez parametrů). Toto makro odstraní ze znalostní baze všechna fakta a poté ji naplní fakty definovanými ve skupinách makrem deffacts. K pouhému vyčištění znalostní baze slouží makro clear (opět bez parametrů).

2.3. Manipulace s odvozovacími pravidly

Definice odvozovacího pravidla se provádí makrem **defrule** a zahrnuje jméno pravidla a seznamy podmínek a aktivací. Podmínky jsou od aktivací odděleny symbolem =>. Vypadá to tedy nějak takto:

```
(defrule find-and-take-green-fruit-to-the-left-of-orange-vegetable
  (green ?x)
  (fruit ?x)
  (orange ?y)
  (vegetable ?y)
   (next-to :left-one ?x :right-one ?y)
=>
    (take ?x)
   (take ?y))
```

Jak je z příkladu zřejmé, podmínky pravidel mohou obsahovat proměnné, jde tedy o patterny. Podmínky mohou být také negované, pak se ověřuje neexistence odpovídajícího faktu ve znalostní bazi. Negované podmínky jsou specifikovány symbolem - (minus) ještě před prvním atomem (či před názvem šablony u složených patternů).

Při opakovaném volání defrule se stejným jménem pravidla dochází k přepsání jeho definice.

K zneplatnění definice pravidla slouží makro undefrule, jehož jediným parametrem je název pravidla.

2.4. Spouštění inferenčního mechanismu

Jakmile jsou systému zadána inicializační fakta a pravidla, je třeba spustit výpočet. Ten pak probíhá v kolech, kde se střídají dvě akce. Nejdříve inferenční machanismus zjistí, která pravidla mají splněné podmínky a jakým faktem je ta která podmínka splněna. Následně je ze seznamu splněných pravidel (agendy vybráno pravidlo a toto je aktivováno. Po vyhodnocení aktivací pravidla se opět aktualizuje seznam splněných pravidel atd.

Výpočet inferenčního mechanismu se spouští funkcí run (bez parametrů). Chceme-li výpočet sledovat po krocíh, můžeme použít funkci step (též bez parametrů), která vždy spustí jen jedno kolo výpočtu.

Dále je k dispozici funkce halt, která výpočet přeruší. Tuto funkci nemá smysl používat samostatně, její volání je ale někdy vhodné zařadit do seznamu aktivací některých pravidel. Tím signalizujeme, že jsou-li podmínky pravidla splněny, dosáhli jsme, čeho jsme chtěli a výpočet může skončit.

2.4.1. Strategie výběru pravidla k aktivaci

Výběr následujícího pravidla k aktivaci je ovlivněn zvolenou strategií. K výběru strategie slouží makro set-strategy, jehož jediným parametrem je název kýžené strategie.

Kromě vestavěných strategií je možné definovat také strategie vlastní. To se provádí makrem **defstrategy**, jemuž předáme název nové strategie a funkci, která z agendy, již dostane parametrem vybere jednu z aktivací a tu vrátí. Definice strategií tedy mohou vypadat třeba takto:

O vestavěných strategiích budu hovořit v následující části textu.

2.5. Sledování změn prostředí

Poslední věcí sloužící k zefektivnění práce s knihovnou je možnost sledovat změny ve znalostní bazi či agendě. Sledovat je možno přidávání či ubíraní faktů do a ze znalostní baze, definice a zneplatnění pravidel a změny v agendě.

Sledování se zapíná makrem watch a vypíná makrem unwatch. Obě makra berou očekávají jako parametr předmět sledování, tedy jeden ze symbolů facts, rules či activations.

2.6. Příklad práce s knihovnou

Na závěr této sekce uvedu krátký příklad práce s knihovnou. Řádky začínající "EXIL>" označují vstup uživatele, zbytek je výstup programu.

```
EXIL> (defrule stop
        (goal :object ?x :to ?y)
        (in :object ?x :location ?y)
        (halt))
#<RULE STOP>
EXIL> (defrule move
        (goal :object ?x :from ?y)
        (in :object ?x :location ?y)
        (- in :object robot :location ?y)
        (in :object robot :location ?z)
        (modify (in :object robot :location ?z)
                (in :object robot :location ?y)))
#<RULE MOVE>
EXIL> (defrule push
        (goal :object ?x :from ?y :to ?z)
        (in :object ?x :location ?y)
        (in :object robot :location ?y)
      =>
        (modify (in :object robot :location ?y)
                (in :object robot :location ?z))
        (modify (in :object ?x :location ?y)
                (in :object ?x :location ?z)))
#<RULE PUSH>
EXIL> (watch facts)
EXIL> (watch activations)
EXIL> (reset)
==> (IN (OBJECT . ROBOT) (LOCATION . A))
==> (IN (OBJECT . BOX) (LOCATION . B))
==> (GOAL (ACTION . PUSH) (OBJECT . BOX) (FROM . B) (TO . A))
==> Activation MOVE:
((GOAL (ACTION . PUSH) (OBJECT . BOX) (FROM . B) (TO . A))
 (IN (OBJECT . BOX) (LOCATION . B))
 (IN (OBJECT . ROBOT) (LOCATION . A)))
NIL
```

```
EXIL> (run)
Firing Activation MOVE:
((GOAL (ACTION . PUSH) (OBJECT . BOX) (FROM . B) (TO . A))
 (IN (OBJECT . BOX) (LOCATION . B))
 (IN (OBJECT . ROBOT) (LOCATION . A)))
<== (IN (OBJECT . ROBOT) (LOCATION . A))
==> (IN (OBJECT . ROBOT) (LOCATION . B))
==> Activation PUSH:
((GOAL (ACTION . PUSH) (OBJECT . BOX) (FROM . B) (TO . A))
 (IN (OBJECT . BOX) (LOCATION . B))
 (IN (OBJECT . ROBOT) (LOCATION . B)))
Firing Activation PUSH:
((GOAL (ACTION . PUSH) (OBJECT . BOX) (FROM . B) (TO . A))
 (IN (OBJECT . BOX) (LOCATION . B))
 (IN (OBJECT . ROBOT) (LOCATION . B)))
<== (IN (OBJECT . ROBOT) (LOCATION . B))
==> (IN (OBJECT . ROBOT) (LOCATION . A))
<== (IN (OBJECT . BOX) (LOCATION . B))
==> (IN (OBJECT . BOX) (LOCATION . A))
==> Activation STOP:
((GOAL (ACTION . PUSH) (OBJECT . BOX) (FROM . B) (TO . A))
 (IN (OBJECT . BOX) (LOCATION . A)))
Firing Activation STOP:
((GOAL (ACTION . PUSH) (OBJECT . BOX) (FROM . B) (TO . A))
 (IN (OBJECT . BOX) (LOCATION . A)))
Halting
NIL
```

Příklad je převzat z [2] a je původně určen pro systém CLIPS.

3. Použité algoritmy

Přiložená implementace expertního systému zahrnuje několik z literatury čerpaných algoritmů. V prvé řadě je to algoritmus Rete, který se stará o pattern matching podmínek odvozovacích pravidel proti faktům znalostní baze, tedy o zjišťování, která odvozovací pravidla je možno aplikovat v dalším kroku výpočtu. Poté je použito několik velice jednoduchých algoritmů pro výběr pravidla, jenž bude jako další aktivováno.

3.1. Algoritmus Rete

Algoritmus Rete (materiály nabízí několik alternativ čtení názvu tohoto algoritmu, mezi nimi "reet" [rýt] či "ree-tee" [rýtý] [1]) kontroluje splnění podmínek inferenčních pravidel fakty znalostní baze. Použití naivního přístupu, tedy zkoušení platnosti všech podmínek proti všem faktům při každé změně znalostní baze není možné, neboť tato kontrola se již při několika stovkách faktů či desítkách pravidel (závisí samozřejmě na výkonu výpočetního hardware, jeho zatížení, atd.) stává příliš časově náročnou.

Algoritmus pracuje na základě dataflow sítě (či chcete-li sítě toku dat), kterou průběžne konstruuje a upravuje při každém přidání či odebrání inferenčního pravidla. Přepočet splněných pravidel algoritmem Rete je o tolik rychlejší díky tomu, že tato síť uchovává v každém uzlu výsledky z minulých výpočtů a nově přidaný (či odebraný) fakt touto sítí jen velice rychle "proteče" a aktualizuje výsledky jen ve velmi malé části uzlů.


Dataflow síť algoritmu je z pohledu teorie grafů spojitý orientovaný graf. Máme-li dva uzly a orientovanou hranu, která je spojuje, budu uzel, z nějž hrana vede, označovat jako rodiče a uzel, do nějž vede, jako potomka. Síť je tvořena dvěma částmi označovanými jako alfa a beta. Navštívení uzlu sítě Rete algoritmu nazýváme aktivací. Některé uzly mohou být aktivovány i více způsoby.

Pozn.: V této práci budu slovo potomek používat v neživotném tvaru. Není to pravděpodobně zcela gramaticky korektní, ovšem označní "ti potomci", mluvímeli o uzlech dataflow sítě, mi přijde poněkud směšné.

Na obrázku 1. je znázorněna dataflow síť Rete algoritmu. Pokud by ovšem mělo znázornění odpovídat používané terminologii, měla by být alfa část sítě na pravé straně. To si ale čtenář jistě snadno představí.

3.1.1. Alfa síť

Alfa část sítě řeší konstantní porovnávání přidávaných faktů s patterny v podmínkách pravidel, ignoruje tedy vazby proměnných a jejich konzistenci. Jde v podstatě o strom, jehož každý uzel testuje právě jeden atom faktu. Kořen alfa sítě je aktivován faktem, faktem aktivuje všechny své potomky. Tyto už provádějí testy jednotlivých atomů, má-li atom požadovanou hodnotu, předá uzel fakt svým



Obrázek 1. Dataflow síť Rete algoritmu[3]

potomkům a ty pokračují v testování. Projde-li fakt všemi konstatními testy, aktivuje poslední testovací uzel fakterm k němu přidružený paměťový alfa-uzel. Ten fakt uloží do své paměti a aktivuje jím své potomky v beta částí sítě.

Kořen alfa části sítě může ještě rozlišovat typ faktu (jde-li o fakt jednoduchý či složený, ve druhém případě pak typ šablony). A podle toho aktivovat faktem jen část potomků.

Pro lepší představu uvedu příklad. Mějme následující pravidlo:

```
(defrule move
  (goal :object ?x :from ?y)
  (in :object ?x :location ?y)
  (- in :object robot :location ?y)
  (in :object robot :location ?z)
  =>
  (modify (in :object robot :location ?z)
  (in :object robot :location ?y)))
```

Kořen alfa sítě tedy bude mít dva potomky - pro šablony goal a in (ignorujme prozatím, že třetí podmínka pravidla je negovaná, to řeší až beta část dataflow sítě). Z uzlu pro šablonu goal povede hrana rovnou do alfa-paměti, všechny zbylé

atomy podmínky jsou totiž proměnné. Z uzlu pro šablonu povede také hrana do další alfa paměti, neboť totéž platí pro druhou podmínku. Bude mít ale i dalšího potomka a to testovací uzel, zda je slot object roven hodnotě robot. Ten pak už aktivuje poslední paměťový alfa-uzel.

Máme tedy dva typové uzly (pro šablony goal a in, jeden testovací uzel a tři uzly paměťové. To zatím není tak působivé, uvědomme si ale, že definujeme-li další pravidlo, které bude mít některé podmínky stejné jako výše uvedené, žádné uzly nám pro tyto podmínky nepřibudou. A budou-li podmínky alespoň podobné, přibudou jen testovací uzly pro atomy patternu, které se budou lišit.

Zde je možno pozorovat první z výhod oproti naivnímu přístupu. Totiž mámeli pravidla se stejnými či podobnými podmínkami, velká část testů se provádí jen jednou, což nám markantně snižuje časovou náročnost výpočtu.

3.1.2. Beta síť

Beta část sítě je opět tvořena několika typy uzlů. Kromě uzlů paměťových jsou zde uzly, které testují konzistenci vazeb proměnných mezi jednotlivými podmínkami inferenčního pravidla, uzly negativních testů a produkční uzly.


Paměťové beta-uzly už neuchovávají jednotlivá fakta, jako je tomu v alfa části dataflow sítě, nýbrž tzv. tokeny, tedy skupiny faktů. Každý paměťový uzel udržuje seznam tokenů, jimiž byly splněny dosavadní podmínky inferenčního pravidla (tzv. partial match). Máme-li tedy pravidlo o čtyřech podmínkách, budeme pro něj potřebovat čtyři paměťové beta-uzly. První uzel uchovává jednomístné tokeny s fakty, které prošly první podmínkou. Neliší se tedy příliš od paměťového alfa-uzlu. Druhý už ale uchovává tokeny s dvojicí faktů - faktem, jenž prošel první podmínkou a faktem, který prošel druhou. Takto se fakta v tokenech nabalují, až máme konečně v posledním uzlu token stejné délky, jako je počet podmínek inferenčního pravidla. Tento uzel označíme jako produkční - je-li aktivován tokenem, našli jsme kompletní shodu faktů s podmínkami pravidal (complete match), v tuto chvíli algoritmus Rete ohlásí nalezení shody (dvojice pravidlo-token) prostředí a ta je přidána do seznamu aktivací.

Hybnou silou beta síťě jsou spojovací uzly (tzv. join node). Ty testují konzistenci vazeb proměnných mezi fakty splňujícími jednotlivé podmínky inferenčního pravidla. Jsou-li vazby konzistentní, uzel vytvoří nový token a aktivuje jím přidružený paměťový beta-uzel. Spojovací uzel může být aktivován dvěma způsoby buď nově přidaným či ubraným (a konstantními testy prošlým) faktem z paměťového alfa-uzlu (tzv. aktivace zprava; toto je místo, kde beta část sítě navazuje na alfa část), nebo tokenem z nadřazeného paměťového beta-uzlu (aktivace zleva). V obou případech ale spojovací uzel prohledá druhou paměť toho druhého rodičovského uzlu pro získání konzistentních tokenů (resp. faktů) a při nalezení shody aktivuje potomky.

Speciálním případem spojovacích uzlů jsou uzly s negativními testy. Tyto mohou být, stejně jako běžné spojovací uzly, aktivovány z obou stran. Podstatný

rozdíl je ale v tom, že negativní spojovací uzel aktivuje své potomky jedině tehdy, nenalezl-li pro daný token žádný konzistentní fakt ve paměti svého rodičovského alfa-uzlu.

Opět uvedu příklad. Zůstaňme u pravidla z příkladu předchozího. Alfa část dataflow sítě pro uvedené pravidlo má tři paměťové uzly. V beta části budeme potřebovat tři spojovací uzly (z nichž jeden bude negativní). První bude testovat konzistenci vazeb mezi prvními dvěma podmínkami pravidla, druhý mezi třetí podmínkou a prvními dvěma, atd. Druhý i třetí spojovací uzel bude mít zprava připojen týž paměťový alfa-uzel (opět recyklace uzlu, tentokrát dokonce v rámci jednoho pravidla). Ke každému spojovacímu uzlu je jako potomek připojen paměťový beta-uzel, který uchovává tokeny s částečnými (v prvních třech případech) či úplnými (ve čtvrtém případě) shodami.



Obrázek 2. Spojovací uzly mezi jednotlivými podmínkami inferenčního pravidla[1]

3.1.3. Přidání/odebrání inferenčních pravidel

Definuje-li uživatel nové inferenční pravidlo je třeba pro něj vytvořit nové či pospojovat již existující uzly dataflow sítě. Algoritmus postupně prochází podmínky pravidla, vytváří (či recykluje) pro každou paměťový beta-uzel a spojovací beta-uzel, který napojí na následující paměťový beta-uzel. Ke každému spojovacímu uzlu také vytvoří (či plně nebo částečně recykluje) cestu v alfa části sítě. Poslední paměťový uzel označí jako produkční a uloží v něm pravidlo aby mohlo

být při splnění všech podmínek předáno spolu s tokenem zpět prostředí a zařazeno do agendy.

Při odstranění pravidla ze systému je pravidlo odstraněno také z odpovídajícího produkčního uzlu a všechny nyní zbytečné uzly jsou ze sítě odstraněny.

3.2. Strategie pro výběr pravidla k aktivaci

Expertní systém je velice obecný výpočetní mechanismus a proto není možné určit jednu odvozovací strategii, která by pokrývala všechny domény problémů, v nichž ho lze využít. Implementace proto poskytuje několik vestavěných strategií pro výběr pravidla z agendy k následné aktivaci a umožňuje i definici uživatelských strategií.

- Strategie nejnovější aktivace (depth strategy) vybírá z agendy pravidlo, které sem bylo přidáno jako poslední. Inferenční mechanismus tedy provádí jakýsi výpočet do hloubky, spouští nově aktivovaná pravidla dokud to lze a teprve při jejich vyčerpání se ve výpočtu vrací k pravidlům aktivovaným dříve.
- Strategie nejstarší aktivace (*breadth strategy*) vybírá z agendy pravidlo, které sem bylo přidáno jako první. Je tedy přesným opakem strategie předchozí, provádí výpočet "do šířky".
- Strategie nejobecnějšího pravidla (simplicity strategy) vybírá pravidlo s nejnižším počtem podmínek, tedy obecnější (statisticky čím méně je podmínek, tím více najdeme shod, které pravidlo splní).
- Strategie nejkonkrétnějšího pravidla (complexity strategy) vybírá pravidlo s nejvyšším počtem podmínek, tedy specifičtější.
- Volně převzato z [2].

4. Popis implementace

Knihovna je napsána v programovacím jazyku Common Lisp. K jejímu vývoji jsem použil textový editor GNU Emacs s rozšířením SLIME (The Superior Lisp Interaction Mode for Emacs) a kompilátor SBCL (Steel Bank Common Lisp). Vývoj jsem prováděl na architektuře GNU/Linux x86. Funkčnost knihovny jsem testoval také ve vývojovém prostředí LispWorks[®].

Zdrojový kód knihovny je rozdělen celkem do 15 soborů:

```
packages.lisp
utils.lisp
templates.lisp
facts.lisp
patterns.lisp
rules.lisp
rete-generic-node.lisp
rete-alpha-part.lisp
rete-beta-part.lisp
rete-net-creation.lisp
matches.lisp
activations.lisp
strategies.lisp
environment.lisp
export.lisp
```

- V souboru packages.lisp definuji package ("balíček") exil, který bude definované funkce, metody a makra obsahovat.
- Soubor utils.lisp obsahuje jednoduché obecné funkce a makra, které jsem během vývoje pro zjednodušení další práce napsal.
- V souboru export.lisp jsou všechny metody a makra, které knihovna poskytuje uživateli. Tyto jsou z package exil exportovány, lze je tedy volat bez nutnosti vstupu do package (před název je třeba připojit "exil:").
- Ve zbytku souborů definuji jednotlivé třídy a metdody. Kód v každém ze souborů staví na konstruktech definovaných v předchozích souborech. Prostředí (třída environment), definovaná ve stejnojmenném souboru nakonec všechny dříve definované třídy zakomponuje do jednoho celku a vytvoří celek, na kterém může soubor export vystavět makra, která uživatel bude nakonec používat.

4.1. Templates

Soubor vytváří základní mechanismus pro práci se strukturovanými daty. Třída template obsahuje sloty pro uchování informací o uživatelsky definovaných šablonách. Všechna strukturovaná data nebo patterny jsou pak instancemi tříd odvozených od template-object. Při vytváření těchto instancí mechanismus prochází kromě inicializačních parametrů také specifikaci slotů uloženou v konkrétní instanci třídy template a tak umožňuje nastavení implicitnch hodnot. Krom toho soubor definuje predikát tmpl-object-specification-p, který podle specifikace faktu (resp. patternu) určí, jde-li o fakt jednoduchý či strukturovaný.

4.2. Facts a Patterns

Definice základních datových struktur fact a pattern a od nich odvozených simple-fact, template-fact, simple-pattern a template-pattern. Nevyžaduje hlubší popis.

4.3. Rules

Definice třídy rule pro uchování inferenčních pravidel. Třída nese informace o jméně pravidla, jeho podmínkách (typu pattern) a aktivacích (prostý seznam lispových výrazů, které se při aktivaci pravidla postupně vyhodnotí).

4.4. Rete

Algoritmus Rete je nejsložitější částí implementace knihovny, jeho kód je tedy pochopitelně nejdelší. Je rozdělen do čtyř souborů.

První z nich, rete-generic-node definuje třídu node, která je základem všech uzlů dataflow sítě algoritmu. Tím je zajištěno, že každý uzel sítě uchovává seznam svých potomků a implementuje metody activate a inactivate, skrze něž je svým rodičem upozorňován na změny ve znalostní bazi. Každý typ uzlu na tyto aktivace reaguje jinak.

Implementace aktivací konkrétních souborů zabírá většinu kódu následujícíh dvou souborů - rete-alpha-part a rete-beta-part. Kořenem celé dataflow sítě algoritmu Rete je alpha-top-node. Ten uchovává hashovací tabulku jednotlivých podsítí alfa-sítě podle typu šablony faktů, které ta která síť testuje. Je zde navíc jedna podsíť pro fakta jednoduchá (ta nemají šablonu).

Jakmile je určena podsíť, jíž bude nově přidaný (resp. odebraný) fakt procházet, je aktivovaný příslušný "podkořen" (alpha-subtop-node), ten už má potomky typu alpha-test-node. Při průchodu každým testovacím uzlem je otestován jeden atom faktu. Poslední testovací uzel předá při kladném výsledku testu fakt paměťovému uzlu (alpha-memory-node), ten si jej uloží a pošle ho beta části sítě.

V souboru rete-beta-part je kromě jednotlivých typů uzlů definována třída token, uchovávající skupinu faktů prošlých podmínkami inferenčního pravidla. Relativně zajímavým prvkej je zde také přístup k testování kozistence vazeb proměnných mezi jednotlivými podmínkami pravidla. Algoritmus zde při aktivaci spojovacího uzlu (beta-join-node a beta-negative-node) vůbec nehledí na konkrétní proměnné, jak by čtenář mohl očekávat. Při tvorbě dataflow sítě je totiž pro každý spojovací uzel vytvořen seznam objektů typu test. Každý test slouží k otestování konzistence jednoho pole aktuální podmínky s předchozími podmínkami. Test obsahuje tři hodnoty - název (v případě strukturovaného patternu podmínky) či index (v případě nestrukturovaného) pole aktuálně testované podmínky, číslo značící, o kolik podmínek zpět má hledat konzistentní pole a název či index tohoto pole.

Pro lepší porozumnění uvedu příklad. Mějme pravidlo

```
(defrule find-green-block-on-a-red-one
  (green ?x)
  (red ?y)
   (on ?x ?y)
=>
  ; zde budou aktivace)
```

a sestavme testy pro beta-join-node testující konzistenci mezi vazbami proměnných ve třetí podmínce proti podmínkám předchozím. Podmínky jsou typu nestrukturovaných patternů, pole číslujme od 0. Test konzistentní vazby proměnné ?x bude mít hodnoty (1 2 1), testujeme totiž pole aktuální podmínky s indexem 1 proti poli s indexem 1 podmínky o 2 zpět. Pokud je prostřední hodnota testu 0, znamená to, že testujeme konzistenci vazby jen v rámci aktuální podmínky. To se může stát, objevuje-li se daná proměnná v podmínce vícekrát. Test vazby proměnné ?y bude mít, jen pro úplnost, hodnoty (2 1 1).

Jak tedy vidíme, hotový beta-join-node na proměnné už vůbec nehledí, jen mechanicky vykoná testy a skončí-li všechny úspěšně, přidá k tokenu fakt prošlý aktuální podmínkou a aktivuje jím své potomky (ty jsou typu beta-memory-node.

Testování se poněkud komplikuje u negativních spojovacích uzlů (beta-negative-node). Zde musíme při každé aktivaci (přidání nového faktu) zkontrolovat, zde není konzistetní s některými z dosud prošlých faktů. Pokud takovou shodu nalezneme, je třeba informovat potomky, aby všechny tokeny s těmito fakty ze svých proměnných odstranily. Při inaktivaci (odstranění faktu ze znalostní baze) je naopak třeba zkontrolovat, zda toho nebyl poslední fakt, který danému tokenu v nesplnění testu bránil (nezapomínejme že je řeč o negativních uzlech). Pokud tomu tak je, je třeba tokenem aktivovat potomky uzlu.

Kdyby nám nezáleželo na efektivitě, bylo by implementačně nejjednodušší po každé aktivaci (resp. inaktivaci) přepočítat možné shody veškerých tokenů v rodičovské beta-paměti proti všem faktům z alfa-paměti. Toto je ale neúnosně

časově náročné. Přidal jsem proto k tomuto účelu do třídy token ještě slot, v němž si token v paměti negativního spojovacího uzlu uchovává seznam konzistentních faktů, jež mu brání v úspěšném nesplnění testů. Když je negativní uzel inaktivován odebráním faktu ze znalostní baze, stačí tedy jen odstranit fakt z těchto seznamů v tokenech a je-li po tomto odstranění seznam některého tokenu prázdný, může tento pokračovat dataflow sítí níže.

Beta-memory-node má kromě uchovávání tokenů ještě jednu funkci - slouží jako produkční uzel - lze v něm uložit seznam pravidel, která jsou uloženými tokeny splněna. Uzel tedy v případě aktivace novým tokenem zkontroluje, zda nějaká pravidla v seznamu má a pokud ano, zavolá metodu add-match a předá jí splněné pravidlo a token, jenž jeho podmínkami prošel. Tento pár (označovaný jako match) je poté přidán k agendě.

4.5. Matches

Soubor matches definuje třídu match. Dokud jsem nezačal implementovat různé strategie pro výběr pravidla k aktivaci, ukládal jsem v agendě jen (pravidlo . token) a této třídy nebylo třeba. Některé strategie ale při výběru pravidla zkoumají, kdy bylo pravidlo na agendu přidáno. To si vyžádalo definici vlastní třídy match, která tuto informaci kromě pravidla a tokenu uchovává.

4.6. Activations

Metody definované v souboru activations řeší samotnou aktivaci pravidla. Výrazy v seznamu aktivací totiž není možné bez předchozí úpravy vyhodnotit, neboť velice často obsahují proměnné navázané v podmínkách. Je tedy třeba z kombinace seznamu podmínek pravidla a tokenu, který pravidlo splnil dostat vazby těchto proměnných. Proměnné v aktivacích jsou poté nahrazeny takto zjištěnými atomy a teprve tehdy je možno aktivace vyhodnotit.

5. Strategies

Soubor strategies obsahuje definice jednotlivých strategií pro výběr pravidla z agendy k následující aktivaci. Jde tedy pouze o seznam funkcí, kterým je agenda jako parametr předána a ony jeden z objektů typu match vrátí. Ten je poté z agendy odstraněn.

5.1. Environment

Reference

- [1] Doorenbos, R. B.: Production Matching for Large Learning Systems. 1995.
- [2] Jackson, P.: *Introduction to Expert Systems*. Addison Wesley, 1998, ISBN 0-201-87686-8.
- [3] Wikipedia: Rete algorithm Wikipedia, The Free Encyklopedia. 2010, [Online].
 - URL <http://en.wikipedia.org/wiki/Rete_algorithm>