PŘÍRODOVĚDECKÁ FAKULTA UNIVERZITY PALACKÉHO KATEDRA INFORMATIKY

DIPLOMOVÁ PRÁCE

Implementace expertního systému v jazyce Common Lisp



2013 Jakub Kaláb

Anotace

Expertní systémy mají v praxi bohaté využití. Jejich smyslem je asistovat expertovi na danou problematiku, či jej plně nahradit. V příloze bakalářské práce implementuji prázdný expertní systém s dopředným řetězením inspirovaný systémem CLIPS jako knihovnu v programovacím jazyku Common Lisp tak, aby jej bylo možno plně integrovat do dalších programů.



Obsah

1.	$\mathbf{U}\mathbf{v}\mathbf{c}$	od		4			
2.	Praktická část						
	2.1.	Potřeb	oná znalost Common Lispu	6			
	2.2.	Instala	nce	8			
		2.2.1.	Získání zdrojového kódu	8			
		2.2.2.	Prerekvizity	8			
		2.2.3.	Načtení knihovny	S			
	2.3.	Uživat	elská příručka	10			
		2.3.1.	Základní pojmy	10			
		2.3.2.	Struktura programu	10			
		2.3.3.	Definice znalostní báze	13			
		2.3.4.	Modifikace pracovní paměti	17			
		2.3.5.	Inference	17			
		2.3.6.	Sledování průběhu inference	21			
		2.3.7.	$\label{eq:Undo/redo} Undo/redo \dots \dots$	22			
		2.3.8.	Zpětná inference	23			
		2.3.9.	Reset prostředí	28			
		2.3.10.	Práce s více prostředími	28			
		2.3.11.	Volání ExiLu z jiného kódu a naopak	29			
		2.3.12.	Kompatibilita se systémem CLIPS	30			
		2.3.13.	Grafické uživatelské rozhraní	33			
	2.4.	Imple	mentace	35			
		2.4.1.	Architektura programu	35			
		2.4.2.	Algoritmus RETE	37			
		2.4.3.	Kompozitní podmínky pravidel	41			
		2.4.4.	$\label{eq:Undo/redo} Undo/redo \dots \dots$	44			
		2.4.5.	Zpětná inference	46			
		2.4.6.	Kompatibilita se systémem CLIPS	49			
		2.4.7.	Grafické uživatelské rozhraní	50			
3.	Teoretická část						
	3.1.	Expert	tní systém	51			
	3.2.	Reprez	zentace znalostí	52			
	3.3.		lní principy	55			
	3.4.		dná a zpětná inference	55			
	3.5.	Interp	retace programu	56			
Re	efere	nce		57			

Seznam obrázků

1.	Grafické uživatelské rozhraní	3
2.	Architektura ExiLu	5
3.	Alpha část sítě RETE	8
4.	Beta část sítě RETE	9
5.	Beta část sítě RETE s funkcemi uzlů	2
6.	Síť RETE s kompozitními podmínkami	3

Seznam příkladů

1	Základní struktura exilového programu	12
2	Definice znalostní báze s použitím strukturovaných faktů	16
3	Definice znalostní báze s použitím CLIPSové syntaxe	32

1. Úvod

Pojem expertního systému spadá do oblasti umělé inteligence. Jde o počítačový systém, který simuluje rozhodování experta nad zvolenou problémovou doménou. Expertní systém může experta zcela nahradit, nebo mu při rozhodování asistovat.

Ve své bakalářské práci [1] jsem implementoval základní knihovnu pro tvorbu expertních systémů (tzv. prázdný expertní systém) s dopředným řetězením v jazyce Common Lisp. Cílem této práce je knihovnu rozšířit o následující:

- syntaktický režim pro zajištění přiměřené kompatibility se systémem CLIPS,
- možnost vrácení provedených změn včetně odvozovacích kroků,
- podpora pro ladění s jednoduchým grafickým uživatelským rozhraním pro prostředí LispWorksTM,
- rozšíření odvozovacího aparátu o základní zpětné řetězení.

Jazyk Common Lisp¹ (případně jiné dialekty Lispu) je častou volbou pro implementaci umělé inteligence díky svým schopnostem v oblasti symbolických výpočtů (manipulace symbolických výrazů), na nichž řešení těchto problémů často staví. Navíc jde o velmi vysokoúrovňový, dynamicky typovaný jazyk, díky čemuž je programový kód expresivní, snadno pochopitelný a tudíž jednoduše rozšiřitelný.

Synax systému CLIPS² byla zvolena proto, že jde o reálně používaný systém³, jehož syntax je Lispu velmi blízká, takže není těžké ji v Lispu napodobit.

Přestože běžnou praxí je začínat diplomovou práci teoretickou částí, definovat jednotlivé pojmy a principy a ty poté v praktické části uplatnit, rozhodl jsem se postupovat opačně, tedy začít práci praktickou částí. Domnívám se totiž (také na základě zkušeností nabytých při vypracování bakalářské práce), že je podstatně snazší, minimálně v řešené problematice, pochopit příklady bez detailní znalosti teorie, než snažit se pochopit teorii bez příkladů, na nichž si lze popisované pojmy a principy představit. V praktické části tedy uvedu jen minimální množtví teorie nutné pro pochopení práce s knihovnou, načež se k ní v teoretické části textu vrátím, pojmy zadefinuji přesně a rozšířím o souvislosti. V tuto chvíli už si bude čtenář schopen představit, jaké problémy lze pomocí expertního systému řešit a jak takový expertní systém v praxi vypadá.

Pro popsaní některé teorie (symbolické výpočty, ...) je navíc užitečná (neli potřebná) představa, jak expertní systém funguje uvnitř.

¹http://en.wikipedia.org/wiki/Common_Lisp

²http://clipsrules.sourceforge.net

³http://clipsrules.sourceforge.net/FAQ.html#Q6

 Kdo už to dělal, čím se tohle liší

2. Praktická část

Tato sekce popisuje knihovnu ExiL⁴, která je výsledkem této práce. Nejprve popíšu její instalaci a prerekvizity nutné k jejímu používání. Pak v uživatelské příručce představím její možnosti a typickou strukturu programu, který ji využívá. Poté v referenční příručce projdu všechny možnosti, které knihovna poskytuje. Načež v části věnované implementaci popíšu architekturu jejího zdrojového kódu a zmíním zajímavé části kódu implementující jednotlivá rozšíření. Nakonec uvedu několik větších příkladů použití knihovny a rozeberu několik dalších možných rozšíření a co by obnášela z pohledu implementace.

2.1. Potřebná znalost Common Lispu

Knihovna ExiL je implementována v jazyce Common Lisp. Pro práci s ní a pochopení její implementace je tedy potřebná znalost tohoto jazyka. Za perfektní příručku k jazku Common Lisp považuji knihu Practical Common Lisp⁵, která je k dispozici online⁶. Následující seznam uvádí relevantní pojmy z Common Lispu a kapitoly z knihy, kde se o nich lze dočíst. V dalším textu budu vždy první výskyt nového pojmu značit kurzívou.

2. Lather, Rinse, Repeat: A Tour of the REPL

implementace lispu, Lispbox, práce s REPLem, obsluha výjimek

4. Syntax and Semantics

prefixová syntax, S-výrazy, funkce, speciální operátory, makra

5. Functions

funkce - definice, typy parametrů, anonymní funkce

6. Variables

proměnné - vytváření vazeb, lexikální proměnné a uzávěry, dynamické proměnné, přiřazení, makra upravující hodnoty proměnných

7. Macros: Standard Control Constructs

řídicí struktury, cykly

8. Macros: Defining Your Own

makra - jejich funkce, vyhodnocování, definice, parametry

10. Numbers, Characters, and Strings

základní vestavěné typy a operace s nimi

⁴původcem názvu knihovny je Zdenek Eichler

⁵Siebel, P.: Practical Common Lisp. Apress, 2005, ISBN 1-59059-239-5.

⁶http://www.gigamonkeys.com/book/

11. Collections

kolekce (pole, hashovací tabulky) a práce s nimi

12. They Called It LISP for a Reason: List Processing

seznamy - reprezentace, operace

13. Beyond Lists: Other Uses for Cons Cells

stromy, množiny, asociativní a property listy, destrukturující makra

16. Object Reorientation: Generic Functions

generické funkce, metody, multimetody, řetězec volání

17. Object Reorientation: Classes

třídy a objekty - definice, sloty, dědičnost

19. Beyond Exception Handling: Conditions and Restarts

práce s výjimkami

20. The Special Operators

kontrola vyhodnocování S-výrazů, kvotování; načítání zdrojových souborů pomocí load

21. Programming in the Large: Packages and Symbols

package a práce se symboly - klíčky, import, export, zastiňování

Jako referenční příručku vestavěných funkcí a maker Common Lispu pak lze použít Common Lisp
 Hyper $\operatorname{Spec}^{\operatorname{TM7}}$.

⁷http://www.lispworks.com/documentation/HyperSpec/Front/

2.2. Instalace

2.2.1. Získání zdrojového kódu

Zdrojový kód knihovny ExiL je přiložen k této diplomové práci a lze jej také získat zklonováním⁸ gitového⁹ repozitáře na adrese git@github.com:Incanus3/ExiL.git. Kód knihovny se nachází v podadresáři src, ten budu dále nazývat kořenovým adresářem knihovny či projektu.

2.2.2. Prerekvizity

Pro práci s knihovnou ExiL potřebujeme lispový interpreter¹⁰, vývojové prostředí (s interpreterem bychom si ve skutečnosti vystačili, ale přímá práce s ním není většinou příliš pohodlná) a knihovny umožňující dávkové načtení celého projektu včetně závislostí.

Knihovnu jsem vyvíjel v prostředí SLIME¹¹, což je plugin pro textový editor GNU Emacs¹² (poskytující mimo jiné pomůcky pro editaci lispového zdrojového kódu, REPL¹³ a debugger) s interpreterem SBCL¹⁴ a tuto kombinaci mohu vřele doporučit. V operačním systému Debian GNU Linux, který jsem pro vývoj použil, lze Emacs, SLIME i SBCL nainstalovat z výchozího repozitáře a aktivovat úpravou inicializačního souboru Emacsu¹⁵. Prostředí poté můžeme v Emacsu spustit voláním příkazu slime (<Alt+X>slime<ENTER>). Při prvním spuštění se kód prostředí kompiluje, což může chvíli trvat, pak už se v editoru otevře buffer¹⁶ s lispovým REPLem.

Knihovnu jsem testoval také ve vývojovém prostředí LispWorks^{®17} Personal Edition 6.1, pro které jsem také vytvořil minimalistické grafické uživatelské rozhraní. Součástí prostředí LispWorks je i lispový interpret. Prostředí můžeme získat na adrese http://www.lispworks.com/downloads/index.html a nainstalovat podle návodu, který se zobrazí po vyplnění formuláře.

Pro efektivní načtení knihovny včetně závislostí potřebujeme ještě dvě knihovny:

⁸http://git-scm.com/docs/git-clone

⁹http://git-scm.com/

 $^{^{10}}$ lispové interpretery jsou většinou zároveň kompilátory, označením interpreter tedy budu nazývat obojí

¹¹http://www.common-lisp.net/project/slime/

¹²http://www.gnu.org/software/emacs/

¹³http://en.wikipedia.org/wiki/Read-eval-print_loop

¹⁴http://www.sbcl.org/

¹⁵http://www.common-lisp.net/projects/slime/doc/html/Installation.html

 $^{^{16}}$ http://www.gnu.org/software/emacs/manual/html_node/emacs/Buffers.html

¹⁷http://www.lispworks.com/

- ASDF¹⁸ je knihovna umožňující snadnou definici struktury projektu a jeho dávkové načtení,
- quicklisp¹⁹ staví na knihovně ASDF a umožňuje pohodlně stáhnout a načíst knihovny třetích stran z internetové databáze.

Knihovna ASDF je součástí instalace interpreteru SBCL i prostředí LispWorks. Knihovnu quicklisp jsem k projektu přiložil a pokud není součástí prostředí, je automaticky načtena před načtením ExiLu.

2.2.3. Načtení knihovny

V prostředí SLIME načteme knihovnu načtením souboru load.lisp z kořenového adresáře knihovny, tedy zadáním

```
(load "cesta/k/projektu/src/load.lisp")
```

v REPLu). Tento soubor nejprve načte knihovnu quicklisp, je-li potřeba, a s její pomocí poté načte celý projekt ExiL včetně závislostí. Nakonec soubor definuje výchozí prostředí, viz sekce 2.3.10.

V prostředí LispWorks načítání pomocí knihovny quicklisp nefunguje správně, knihovnu je proto třeba načítat načtením souboru load-manual.lisp (opět z kořenového adresáře projektu). Načíst můžeme opět voláním load v REPLu, nebo vybráním položky Load... v nabídce File menu libovolného okna prostředí.

Všechna makra a funkce, které knihovna definuje pro přímé volání uživatelem jsou *exportována* z *package* exil. Před interakcí s knihovnou je tedy třeba vstoupit do package exil-user, který symboly z package exil *importuje*. Symboly z package je také možno importovat do existujícího package takto:

```
(defpackage :my-package
  (:documentation "user-defined package")
  (:use :common-lisp :exil)
  (:shadowing-import-from :exil :assert :step))
```

Package exil exportuje několik symbolů, které již v package common-lisp existují. Ty je třeba *zastínit*, jak je vidět z ukázky.

¹⁸http://common-lisp.net/project/asdf

¹⁹http://www.quicklisp.org/beta/

2.3. Uživatelská příručka

2.3.1. Základní pojmy

Nyní stručně zadefinuji základní pojmy, nutné pro pochopení fungování knihovny ExiL a práci s ní. Význam pojmů bude jasnější, jakmile si je ukážeme na příkladech. K těmto pojmům se posléze vrátím i v teoretické části textu a jejich popis rozšířím o další souvislosti.

První dva pojmy staví na pojmu znalost, který chápeme intuitivně, nikoli na následujícím pojmu znalost, jak jej chápeme v ExiLu (v takovém případě by byla definice cyklická).

Pojem expertního systému zatím chápejme tak, jak jsem jej představil v úvodu práce. V teoretické části rozeberu pojem v potřebné šíři.

fakt elementární statická znalost - tvrzení

(odvozovací) pravidlo elementární odvozovací znalost ve formě implikace

znalost (v ExiLu) množina faktů a pravidel

znalostní báze výchozí znalost expertního systému

pracovní paměť aktuální množina faktů

inference odvozování - postupná aplikace pravidla modus po-

nens²⁰ na konjunkci faktů a odvozovací pravidlo

Pojem pracovní paměť není příliš intuitivní. Jde o doslovný překlad v literatuře užívaného pojmu working memory, kterým je označována množina faktů (tvrzení), které expertní systém v danou chvíli považuje za platné. Nejde tedy ve skutečnosti o paměť, nýbrž o obsah pomyslné paměti. Pojem pracovní množina faktů by byl jistě výstižnější, bohužel ale také značně těžkopádný.

2.3.2. Struktura programu

Příklad 1 na straně 12 ukazuje minimální strukturu programu nad knihovnou ExiL (dále exilový program). První část programu tvoří definice znalostní báze. Ta sestává z definic faktů, ze kterých expertní systém vychází, a definic odvozovacích pravidel, jež jsou následně aplikována při inferenci.

Definice faktů jsou uspořádány do skupin označených názvem (v tomto případě world). V ukázkovém programu si snadno vystačíme s jednou skupinou faktů, v reálných programech bude ale těchto skupin většinou více. Tato organizace umožňuje snadnou redefinici, případně odebrání, jen některých skupin faktů v případě potřeby. Definice skupiny faktů world v příkladu přidává do znalostní

²⁰http://en.wikipedia.org/wiki/Modus_ponens

báze informaci o počáteční pozici robota, krabice a o našem záměru přesunout krabici z pozice A na pozici B.

Následuje definice odvozovacích pravidel. Definice každého pravidla sestává z jeho názvu, volitelného řetězce sloužícího k dokumentaci pravidla, množiny podmínek, tedy předpokladů pro jeho splnění (a následnou aktivaci), a množiny důsledků, tedy libovolných lispových výrazů, které jsou při aktivaci pravidla vyhodnoceny. Tyto dvě množiny jsou od sebe odděleny symbolem =>.

Podmínky odvozovacích pravidel jsou ve formě vzorů (pattern). Struktura vzorů je stejná jako struktura faktů (viz sekce 2.3.3.), ale na rozdíl od nich mohou obsahovat proměnné (symboly začínající otazníkem). Při vyhodnocování podmínek pravidla je zajišťěna konzistence vazeb těchto proměnných a výskyty všech proměnných v důsledcích pravidla jsou při jeho aktivaci nahrazeny jejich vazbami. Detaily viz sekce 2.3.5.

Důsledky pravidel typicky obsahují příkazy pro modifikaci pracovní paměti (viz sekce 2.3.4.), tedy přidání (assert), odebrání (retract), či úpravu (modify) faktů v ní. Nemusí tomu tak ale být vždycky - důsledkem aktivace pravidla může být např. vypsání výstupu, logování, zápis souboru, ale také např. ovládání externího systému.

Ukázkový příklad definuje tři odvozovací pravidla. Pravidlo move-robot je aktivováno, pokud chceme přesunout nějaký objekt z pozice ?from na pozici ?to, objekt se nachází v pozici ?from a robot nikoli (třetí podmínka je negovaná, viz sekce 2.3.5.). Poslední podmínka slouží pouze k navázání původní pozice robota. Při aktivaci pravidla je v pracovní paměti nahrazena informace o původní pozici robota pozicí ?from. Robot se tedy nyní nachází na stejné pozici, jako kýžený objekt.

Podmínky pravidla move-object vyžadují, aby byl jak robot, tak objekt určený k přesunu, na pozici ?from. Při jeho aktivaci je robot i s objektem přesunut na pozici ?to nahrazením faktů o původních pozicích novými, podobně jako v prvním pravidle. Definice pravidla obsahuje speciální notaci (s použitím operátoru <-), jejímž účelem je navázání celého faktu na proměnnou. Ten pak můžeme v důsledcích snadno ostranit z pracovní paměti. Detaily opět viz sekce 2.3.5.

Poslední pravidlo slouží k zastavení inference, pokud se již objekt nachází na cílové pozici. Inference je zde zastavena explicitním voláním (halt). Druhou možností by bylo odstranit z pracovní paměti fakt definující cíl (jak vidíme v příkladu 2), neboť v takovou chvíli nemůže být žádné další pravidlo splňeno.

Jakmile je znalostní báze nadefinována, můžeme z ní inicializovat pracovní paměť. To provedeme voláním (reset), které (po případném vyčištění původních faktů) přidá do pracovní paměti fakty ve všech definovaných skupinách.

Poslední nutnou fází exilového programu je spuštění inference. To můžeme udělat nejjednodušeji voláním (run). Inferenční mechanismus poté postupně vyhodnocuje, která odvozovací pravidla mají splněné všechny podmínky, v každém kroku z nich jedno vybere a aktivuje jej. Detaily viz sekce 2.3.5.

```
;;; definition of knowledge base
   ;; facts
   (deffacts world
      (in box A)
      (in robot B)
      (goal move box A B))
   ;; inference rules
   (defrule move-robot
     "move robot to object's location"
10
     (goal move ?object ?from ?to)
11
      (in ?object ?from)
12
     (- in robot ?from)
     (in robot ?z)
14
     (retract (in robot ?z))
16
     (assert (in robot ?from)))
18
   (defrule move-object
     "move robot and object to desired location"
20
     (goal move ?object ?from ?to)
21
     ?rob-pos <- (in robot ?from)</pre>
22
     ?obj-pos <- (in ?object ?from)</pre>
23
     =>
24
     (retract ?rob-pos)
25
     (retract ?obj-pos)
26
     (assert (in robot ?to))
27
      (assert (in ?object ?to)))
28
29
   (defrule stop
30
     "stop if object is in desired location"
31
     (goal move ?object ?from ?to)
32
     (in ?object ?to)
33
     =>
     (halt))
35
   ;;; initialization of working memory
37
   (reset)
   ;;; inference execution
40
   (run)
41
```

Příklad 1: Základní struktura exilového programu

Výstup programu je následující:

```
==> (IN ROBOT B)
==> (IN BOX A)
==> (GOAL MOVE BOX A B)
Firing MOVE-ROBOT
<== (IN ROBOT B)
==> (IN ROBOT A)
Firing MOVE-OBJECT
<== (IN ROBOT A)
<== (IN ROBOT A)
<== (IN BOX A)
==> (IN ROBOT B)
==> (IN BOX B)
Firing STOP
Halting
```

Řádky začínající symbolem ==> označují fakty přidané do pracovní paměti, řádky začínající <== fakty z paměti odstraněné. Tento výstup obdržíme pouze pokud zapneme sledování faktů voláním (watch facts) (viz sekce 2.3.6.). První tři fakty přibydou do pracovní paměti při vyhodnocení volání (reset), další pak spolu s postupnou aplikací odvozovacích pravidel. Dotážeme-li se po skončení inference na seznam faktů v pracovní paměti voláním (facts), obdržíme výstup

```
((GOAL MOVE BOX A B) (IN ROBOT B) (IN BOX B)).
```

Robot i krabice jsou tedy na cílové pozici.

Kód exilového programu má deklarativní charakter. Nikde jsme nemuseli specifikovat, jakou posloupností akcí má systém k výsledku dospět. To nás ovšem nezbavuje nutnosti chápat fungování inferenčního mechanismu ExiLu. Nebudeme-li při konstrukci programu opatrní, může výpočet snadno dospět k neočekávaným výsledkům, dostat se do slepé větve, či se zacyklit. Tyto problémy jsou často způsobeny nezamýšlenou interferencí podmínek pravidel s důsledky jiných.

Skupina pravidel může například snadno cyklit, pokud první pravidlo závisí na neexistenci nějakého faktu, tento v důsledcích přidá, načež je tento fakt posledním pravidlem odstraněn, aniž by byla v průběhu zneplatněna nějaká další podmínka prvního pravidla. Fakt, který odvodíme v jedné část programu může také neočekávaně splnit podmínku pravidla definovaného v úplně jiné části, která s první neměla vůbec přímo komunikovat.

2.3.3. Definice znalostní báze

ExiL, stejně jako CLIPS, rozlišuje dva typy faktů - jednoduché (simple, ordered) a strukturované (templated). Stuktura jednoduchého faktu je udána pouze pořadím atomů, typickou volbou je např. objekt-attribut-hodnota:

```
(box color red),
či relace-objekty:
(in box hall).
```

Strukturované fakty mají naproti tomu explicitně pojmenované složky (sloty). Typicky popisují objekt s množinou pojmenovaných atributů:

```
(box :color red :size small),
či relaci s pojmenovanými aktory:
(in :object box :location hall),
```

kde box a in jsou šablony (template), které je třeba definovat předem. Na pořadí specifikace slotů u strukturovaných faktů nezáleží.

Vyjadřovací síla obou typů faktů je stejná, použitím explicitnějších strukturovaných faktů ale docílíme lepší čitelnosti a jednoznačnější sémantiky exilového programu, zvláště třeba v případě relací na jedné množině objektů:

```
(father john george).
```

Šablonu definujeme voláním makra deftemplate, např:

```
(deftemplate in object (location :default here)).
```

Prvním parametrem je název šablony, za ním následuje libovolný počet specifikací slotů. Specifikací slotu je buď symbol - jméno slotu, nebo seznam, jehož hlavou (car) je jméno slotu a tělem (cdr) je property list (plist) s dalšími parametry. Aktuálně systém umožňuje pouze specifikaci výchozí hodnoty slotu klíčem :default. Ta je použita, není-li při specifikaci faktu, používajícího tuto šablonu, uvedena hodnota pro daný slot. Příklad 2 na straně 16 ukazuje definici znalostní báze ekvivalentní příkladu 1 s použitím strukturovaných faktů.

Je-li už šablona požadovaného názvu definována, ale neexistují v pracovní paměti fakty, které ji používají, je její stávající definice nahrazena. Pokud ale v pracovní paměti existují takové fakty, skončí volání deftemplate výjimkou.

Seznam názvů všech definovaných šablon můžeme získat voláním (templates). Specifikaci šablony pak získáme voláním makra find-template, např. (find-template in). Definici šablony zrušíme voláním makra undeftemplate, např. (undeftemplate goal). To opět skončí výjimkou, existují-li v pracovní paměti fakty, které šablonu využívají.

Fakty, ze kterých expertní systém vychází, zavádíme pomocí skupin faktů. Ty definujeme makrem deffacts, např.:

```
(deffacts initial
  (goal move box A B)
  (in :object box :location A))
```

Prvním parametrem je název skupiny, pak následuje libovolný počet specifikací faktů. Opakovaným voláním makra deffacts je skupina faktů redefinována.

Specifikace faktu je vždy tvořena seznamem. Pokud jde o jednoduchý fakt, specifikací je prostě seznam atomů. Jde-li o fakt strukturovaný, je prvním prvkem specifikace název šablony, za ním následuje plist určující hodnoty slotů faktu. Pokud není hodnota některého slotu uvedena, je buď použita výchozí hodnota, pokud byla v šabloně specifikována, nebo hodnota nil v opačném případě.

Seznam názvů všech definovaných skupin faktů získáme voláním (fact-groups). Specifikaci skupiny pak voláním makra find-fact-group, např. (find-fact-group initial). Ke zrušení definice skupiny slouží makro undeffacts (voláme s názvem skupiny).

Pravidla, pomocí nichž expertní systém během inference odvozuje nové fakty, definujeme makrem defrule, např.:

```
(defrule move-robot
  "move robot to object's location"
  (goal :action move :object ?obj :from ?from)
  (in :object ?obj :location ?from)
  (- in :object robot :location ?from)
  ?robot <- (in :object robot :location ?)
  =>
  (modify ?robot :location ?from)).
```

Podmínková část pravidla (před symbolem =>) je tvořena vzory. Ty mohou být, stejně jako fakty, jednoduché, nebo strukturované. Kromě toho umožňuje definice pravidla několik speciálních konstruktů (negace podmínky, navázání proměnné na celou podmínku). Ty popíšu podrobně v sekci 2.3.5. spolu s tím, jak jsou podmínky pravidla při inferenci vyhodnocovány.

Důsledkovou část pravidla (za symbolem =>) tvoří libovolný počet lispových výrazů. Jak se tyto vyhodnocují popíšu opět v sekci 2.3.5.

Opakovaným voláním makra defrule odvozovací pravidlo redefinujeme. K získání seznamu názvů definovaných pravidel a jejich specifikací slouží *funkce* rules a makro find-rule, podobně jako u šablon a skupin faktů. Ke zrušení definice pravidla slouží makro undefrule.

```
(deftemplate goal (action :default move) object from to)
   (deftemplate in object location)
   (deffacts world
      (in :object robot :location A)
      (in :object box :location B)
      (goal :object box :from B :to A))
   (defrule move-robot
      (goal :object ?obj :from ?from)
10
      (in :object ?obj :location ?from)
      (- in :object robot :location ?from)
12
     ?robot <- (in :object robot :location ?)</pre>
14
      (modify ?robot :location ?from))
15
16
   (defrule move-object
17
      (goal :object ?obj :from ?from :to ?to)
18
     ?object <- (in :object ?obj :location ?from)</pre>
19
     ?robot <- (in :object robot :location ?from)</pre>
20
21
      (modify ?robot :location ?to)
22
      (modify ?object :location ?to))
23
24
   (defrule stop
25
     ?goal <- (goal :object ?obj :to ?to)</pre>
26
      (in :object ?obj :location ?to)
27
      (retract ?goal))
29
```

Příklad 2: Definice znalostní báze s použitím strukturovaných faktů

2.3.4. Modifikace pracovní paměti

Pracovní paměť je množina faktů, které systém v danou chvíli považuje za platné. Její obsah můžeme vypsat voláním funkce facts. Funkcí reset inicializujeme pracovní paměť ze znalostní báze. Jejím voláním jsou do pracovní paměti zavedeny fakty všech definovaných skupin faktů (viz sekce 2.3.3.).

Obsah pracovní paměťi může být dále modifikován třemi makry:

- assert přidává fakt(y) do pracovní paměti,
- retract fakt(y) z pracovní paměti odebírá a
- modify přímo modifikuje existující fakt.

Ta lze volat buď před započetím inference (ale po volání reset, neboť to dodatečné úpravy vymaže), nebo v jejím průběhu, pokud inferenci krokujeme (viz sekce 2.3.5.). Makra také typicky voláme v důsledcích pravidel.

Makra assert a retract berou jako parametry libovolný počet specifikací faktů ve stejném formátu, jako u makra deffacts (ale bez názvu skupiny). Makro modify lze použít jen u strukturovaných faktů. Toto makro bere jako první parametr specifikaci faktu, zbytek parametrů tvoří plist určující hodnoty slotů ke změně. Např.

```
(modify (in :object box :location A) :location B)
```

nahradí v pracovní paměti fakt (in :object box :location A) faktem (in :object box :location B). Toto makro je obzvláště užitečné, navážeme-li v podmínkách pravidla celý fakt na proměnnou (viz sekce 2.3.5.).

Pracovní paměť se skutečně chová jako množina, každý fakt tedy může být v pracovní paměti jen jednou. Opětovné volání assert nemá žádný efekt. Volání modify, jehož výsledkem by bylo nahrazení nějakého faktu faktem, který již v pracovní paměti existuje, sice odebere původní fakt, nový však znovu nepřidá.

Všechny fakty můžeme z pracovní paměti odebrat voláním (retract-all). To je ale zřídka užitečné, typicky použijeme spíše funkci reset pro navrácení pracovní paměti do výchozího stavu.

2.3.5. Inference

Inference (odvozování nových faktů z aktuálních) probíhá v krocích. V každém kroku jsou vyhodnoceny podmínky všech pravidel, načež je ze splněných pravidel vybráno jedno, které je posléze aktivováno. Inferenční kroky můžeme buď spouštět jednotlivě voláním (step), nebo voláním (run) spustit cyklus, který provádí inferenční kroky, dokud je to možné. Cyklus je buď přerušen ve chvíli, kdy není splněno žádné další pravidlo, nebo voláním (halt) v důsledcích právě aktivovaného pravidla.

Podmínky pravidel jsou ve tvaru vzorů a jsou spojeny logickou konjunkcí, pravidlo je tedy splněno, jsou-li splněny všechny jeho podmínky. Kromě toho mohou být některé podmínky negovány. Taková podmínka je splněna tehdy, neexistuje-li v pracovní paměti žádný fakt, který by se shodoval s jejím vzorem (při zachování konzistence vazeb proměnných). Negovanou podmínku značí znak – (minus) na prvním místě specifikace vzoru.

Vyhodnocování podmínek pravidel probíhá ve dvou fázích. V první fází srovnáváme vzory jednotlivých podmínek se všemi fakty v pracovní paměti a to pouze strukturálně, tedy bez ohledu na vazby proměnných. Prvním požadavkem shody je u jednoduchých faktů stejná délka (počet atomů), u strukturovaných faktů stejná šablona. Jednoduchý fakt se nikdy nemůže shodovat se strukturovaným vzorem a naopak.

Dále jsou pak porovnávány jednotlivé atomy (u jednoduchých) či sloty (u složených) faktu vůči odpovídajícímu atomu (slotu) vzoru. Není-li atom (slot) vzoru proměnná, je jednoduše porovnán s atomem faktu. Je-li atomem proměnná, považujeme jej v této fázi automaticky za shodu. Například vzor

```
(in :object robot :location ?loc)
se shoduje s faktem
(in :object robot :location A)
nikoli však s fakty
(in :object box :location A)
(is-in :object robot :location A)
(in robot A).
```

Tímto předvýběrem tedy získáme ke každé podmínce pravidla množinu faktů, které mají stejnou strukturu a stejné hodnoty neproměnných atomů.

Ve druhé fázi vyhodnocování hledáme z předvybraných faktů takovou posloupnost (délka odpovídá počtu podmínek pravidla), kde po spárování s odpovídajícími vzory podmínek obdržíme konzistentní vazby proměnných. To znamená, že vyskytuje-li se v podmínkách pravila některá proměnná vícekrát, musí mít odpovídající fakty na daných pozicích stejný atom. Mějme například pravidlo s podmínkami

```
(goal move ?obj ?from ?to)
(in :object ?obj :location ?from)
(in :object robot :location ?to).
```

Vzor první podmínky je jednoduchý, zatímco další dva jsou strukturované. To ale ničemu nevadí, je třeba pouze najít fakty odpovídající struktury. Posloupnost faktů

```
(goal move box A B)
(in :object box :location B)
(in :object robot :location A)
```

neprojde druhou fází výběru, neboť vazby proměnných nejsou konzistentní. Proměnná ?from je například v první podmínce navázána na symbol A, v druhé ale na B. Kdyby si ovšem krabice s robotem vyměnily pozice, budou vazby proměnných konzistentní a podmínky pravidla budou splněny. Proměnná ?from by pak nabyla hodnoty A, proměnná ?to hodnoty B a proměnná ?obj hodnoty box.

Vyhodnocení negovaných podmínek si můžeme představit tak, že nejprve vyhodnotíme a navážeme proměnné všech ostatních podmínek. Pokud poté neexistuje fakt, který by se se vzorem negované podmínky shodoval a měl konzistentní vazby se zbytkem navázaných proměnných, je tato podmínka splněna. Mějme například pravidlo s podmínkami

```
(goal move box ?from ?to)
(in box ?from)
(- in robot ?from).

Máme-li v pracovní paměti pouze fakty
(goal move box A B)
(in box A)
(in robot B),
```

budou podmínky pravidla splněny, neboť po spárování vzorů prvních dvou podmínek s prvními dvěma fakty bude proměnná ?from navázána na hodnotu A a neexistuje fakt, který by se shodoval se vzorem (in robot A). Přesuneme-li ale robota na pozici A, podmínka již splněna nebude a pravidlo nelze aktivovat.

Ve vzorech podmínek pravidla můžeme využít speciální proměnné?. Konzistence vazby této proměnné není při vyhodnocování testována, takže vyskytuje-li se tato proměnná na více místech, chová se tak, jako kdyby byl každý výskyt označen unikátním názvem (podobně jako proměnná _ v Prologu). Použitím této proměnné dáváme najevo, že nás konkrétní hodnota daného atomu nazajímá. Ve strukturovaných vzorech podmínek není třeba tyto sloty uvádět, neboť? je výchozí hodnotou slotu vzoru.

Posledním speciálním konstruktem je navázání celého faktu na proměnnou. Například pravidlo

```
(defrule move
  ?fact <- (in :object ? :location A)
  =>
    (modify ?fact :location B))
```

přesune každý objekt z pozice A na pozici B. Na proměnnou můžeme navázat i jednoduchý fakt, pak ale nemůžeme použít makra modify. Můžeme ovšem volat (retract ?fact), neboť proměnná ?fact je při aktivaci pravidla nahrazena specifikací faktu, který byl se vzorem podmínky spárován.

Podmínky některých pravidel mohou být při vyhodnocování splněny několika různými posloupnostmi faktů. Výsledkem vyhodnocování pravidel tedy není pouze množina splněných pravidel, nýbrž množina shod (match). Každá shoda je tvořena pravidlem a substitucí proměnných navázaných při vyhodnocování jeho podmínek. Substituci chápejme jako zobrazení z množiny všech proměnných, vyskytujících se v podmínkách pravidla, na konkrétní hodnoty atomů (slotů). Aplikací této substituce na vzory podmínek pravidla získáme opět posloupnost faktů, kterými byly podmínky v dané shodě splněny. Tato substituce je následně použita při aktivaci pravidla k náhradě proměnných v jeho důsledcích.

ExiL uchovává aktuální množinu shod. Ta ve skutečnosti není přepočítána v první fázi inferenčního kroku, jak jsem dosud pro jednoduchost tvrdil, nýbrž automaticky po každé změně pracovní paměti či množiny pravidel (detaily viz RETE). Aktuální množinu shod nazývám, po vzoru CLIPSu, agenda a lze ji vypsat voláním stejnojmenné funkce. Každá shoda v agendě je opatřena časovým razítkem, shody je tedy možné uspořádat podle toho, kdy do agendy přibyly.

Je-li na začátku inferenčního kroku v agendě více shod, je třeba z nich jednu vybrat k aktivaci. Výběr shody záleží na zvolené strategii. ExiL poskytuje následující strategie výběru shody:

depth-strategy vybírá shodu, která do agendy přibyla nejpozději vybírá shodu, která do agendy přibyla jako první simplicity-strategy vybere shodu, jejíž pravidlo má nejméně podmínek complexity-strategy volí shodu, jejíž pravidlo má nejvíce podmínek.

Názvy prvních dvou strategií vychází z toho, že jde o prohledávání prostoru stavů systému do hloubky, či do šířky, jak blíže popíšu v teoretické části textu, spolu s motivacemi pro využití jednotlivých typů strategií a dalšími typy strategií, které se v expertních systémech používají.

Výchozí strategií je depth-strategy. Strategii, která bude v inferenci použita, můžeme zvolit voláním makra setstrategy s názvem strategie, např. (setstrategy breadth-strategy). Seznam názvů strategií můžeme vypsat voláním (strategies), název aktuálně zvolené strategie pak voláním (current-strategy).

Po výběru shody k aktivaci je její pravidlo aktivováno. Nejprve jsou v důsledcích pravidla nahrazeny všechny proměnné pomocí substituce shody. Výrazy v důsledcích jsou poté vyhodnoceny lispovým makrem eval. Tento způsob vyhodnocení vede ke značným omezením. Výrazy totiž nejsou vyhodnoceny v lexikálním prostředí definice pravidla, nýbrž ve výchozím (top-level) prostředí Lispu.

Díky tomu nemůžeme v důsledcích pravidla volat lokální funkce (definované např. makrem labels), či přistupovat k lokálním proměnným (navázaným například v letu či pomoci destrukturujících maker).

V důsledcích každého pravidla chceme typicky alespoň jednou volat některé z maker modifikujících pracovní paměť, abychom zneplatnili podmínky pravidla, jinak se inference zacyklí. Druhou možností je přerušit inferenci voláním (halt). Volání (step) nebo (run) ve chvíli, kdy již nelze dále odvozovat (žádné z pravidel nemá splněné podmínky), nemá žádný efekt.

2.3.6. Sledování průběhu inference

ExiL umožnuje sledovat několik typů událostí, ke kterým dochází během inference. K nastavení sledovaných událostí slouží makra watch a unwatch. K zjištění stavu sledování pak makro watchedp.

Základním výstupem programu 1 na straně 12 je

```
Firing MOVE
Firing PUSH
Firing STOP
Halting.
```

Zapneme-li sledování faktů voláním (watch facts), obdržíme výstup

```
==> (IN BOX A)
==> (IN ROBOT B)
==> (GOAL MOVE BOX A B)
Firing MOVE-ROBOT
<== (IN ROBOT B)
==> (IN ROBOT A)
Firing MOVE-OBJECT
<== (IN ROBOT A)
<== (IN BOX A)
==> (IN ROBOT B)
==> (IN ROBOT B)
Firing STOP
Halting.
```

Sledování pravidel ((watch rules)), přidává informace o pravidlech přidaných do (odebraných ze) znalostní báze, např.

```
==> (RULE STOP
  (GOAL MOVE ?OBJECT ?FROM ?TO)
  (IN ?OBJECT ?TO)
  =>
  (HALT)).
```

Po zapnutí sledování agendy (voláním (watch activations), název je kvůli kompatibilitě se systémem CLIPS) budeme navíc informováni o shodách, které do agendy přibyly, nebo z ní byly odstraněny. Výstup programu pak bude následující:

Každá shoda je zde reprezentována názvem pravidla a posloupností faktů, které byly spárovány s jeho podmínkami. Odtud můžeme snadno odvodit substituci, jež byla při vyhodnocení použita. Negované podmínky nejsou spárovány s žádným konkréním faktem, proto jsou zde jen tři fakty, přestože pravidlo move-robot má podmínky čtyři.

Je zde také vidět, že po aktivaci pravidla move-robot se v agendě na chvíli objeví opětovná shoda tohoto pravidla. To je způsobeno tím, že obsah agendy se přepočítává po každé změně pracovní paměti, takže se zde mohou objevit dočasné výsledky.

2.3.7. Undo/redo

Jedním z implementovaných rozšíření původního programu je schopnost vrácení provedených změn. K tomu slouží makra undo a redo. Ta lze použít k vrácení jakékoli akce s vedlejším efektem, včetně kroků inference. K vypsání zásobníků s akcemi, které je možné vrátit, jsou k dispozici makra undo-stack a redo-stack.

Pokud například vyhodnotíme prvních 32 řádků programu 1 na straně 12 a zavoláme dvakrát undo, bude výpis zásobníků následující (přeformátováno):

```
EXIL-USER> (undo-stack)
  1: (defrule MOVE-ROBOT
       ((GOAL MOVE ?OBJECT ?FROM ?TO)
        (IN ?OBJECT ?FROM)
        (- IN ROBOT ?FROM) (IN ROBOT ?Z)
        (RETRACT (IN ROBOT ?Z))
        (ASSERT (IN ROBOT ?FROM))))
  2: (deffacts WORLD
       ((IN BOX A) (IN ROBOT B) (GOAL MOVE BOX A B)))
EXIL-USER> (redo-stack)
  1: (defrule MOVE-OBJECT
       ((GOAL MOVE ?OBJECT ?FROM ?TO)
        ?OBJ-POS <- (IN ?OBJECT ?FROM)</pre>
        ?ROB-POS <- (IN ROBOT ?FROM)</pre>
        =>
        (RETRACT ?ROB-POS)
        (RETRACT ?OBJ-POS)
        (ASSERT (IN ROBOT ?TO))
        (ASSERT (IN ?OBJECT ?TO))))
  2: (defrule STOP
       ((GOAL MOVE ?OBJECT ?FROM ?TO)
        (IN ?OBJECT ?TO)
        =>
        (HALT)))
```

Vidíme tedy, že jsme vrátili zpět definice pravidel move-object a stop (ty bychom mohli opět provést voláním (redo)). Dalším voláním (undo) by pak byla vrácena definice pravidla move-robot a poté definice skupiny faktů world.

Nemá-li akce žádný vedlejší efekt - např. volání assert s faktem, který už v pracovní paměti je, či volání run ve chvíli, kdy už není co odvozovat - prázdná akce se na zásobník neuloží.

2.3.8. Zpětná inference

Dalším z implementovaných rozšíření je možnost zpětné inference. Inference popsaná v sekci 2.3.5. je dopředná. V každém kroku jsou nalezeny všechny možnosti dalšího postupu odvozování, načež je zvolena jedna, kterou se program dále ubírá. To činí průběh inference značně nedeterministickým. Možnosti postupu, které nebyly vybrány, mohou být navíc dalším postupem ztraceny, pokud aktivace některého pravidla zneplatní podmínky jiného. Míru nedeterminismu můžeme snížit tím, že budeme navrhovat odvozovací pravidla tak, aby se výpočet neubíral nechtěnými cestami. To ale není vždy jednoduché, nebo dokonce možné.

Zpětná inference naproti tomu umožňuje definovat cíle, kterých chceme dosáhnout. K tomu slouží makro defgoal, kterému předáme vzor ve stejném formátu, jako u podmínek pravidel. Definice cíle ovšem nepodporuje negaci ani navázání faktu na proměnnou (k tomu ani není důvod). Cíle je pak možné vypsat voláním (goals). Cíl můžeme také odebrat makrem undefgoal. Ke spuštění zpětné inference slouží funkce back-step a back-run, podobně jako u inference dopředné.

Mějme následující znalostní bázi:

```
(deffacts world
   (have-money))

(defrule buy-car
   (have-money)
   =>
   (retract (have-money))
   (assert (have-car)))

(defrule pay-rent
   (have-money)
   =>
   (retract (have-money))
   (assert (rent-payed))).
```

Spustíme-li dopřednou inferenci, systém nám vesele doporučí nákup auta. Mít nové auto je sice pěkné, hrozí-li nám ale vyhození z pronajatého bytu, není nákup auta pravděpodobně cestou, kterou bychom se chtěli ubírat. Systém by nám v tuto chvíli mohl stejně dobře doporučit správnou cestu. Že bylo vybráno zrovna první pravidlo je výsledkem toho, jak funguje síť RETE, která pravidla vyhodnocuje. Za daných okolností ale nechceme špatnou variantu ani připouštět.

V tomto případě bychom mohli upravit definici programu tak, že do znalostní báze přidáme informaci o cíli, kterou budou pravidla zohledňovat, podobně jako v příkladu 1 na straně 12. Muset ale programovat zohlednění cíle v každém pravidle je přinejmenším otravné. U větších programů to navíc může být velmi náročné, neboť cíl bude třeba programově modifikovat v průběhu výpočtu.

S použitím zpětné inference je problém podstatně jednodušší. Zavoláme-li

```
(reset)
(defgoal (rent-payed))
(back-run),
bude výsledkem výstup
```

```
All goals have been satisfied
(RENT-PAYED) satisfied by (RULE PAY-RENT
  (HAVE-MONEY)
=>
  (RETRACT (HAVE-MONEY))
  (ASSERT (RENT-PAYED)))
(HAVE-MONEY) satisfied by (HAVE-MONEY).
```

Zde vidíme, že po spuštění zpětné inference nezačal systém bezhlavě provádět akce, ke kterým měl dostatečné prostředky. Místo toho systém uvážil zadaný cíl a jal se hledat akce, které k jeho splnění směřují.

Uvažme nyní složitější příklad (definice šablon vynechána):

```
(deffacts world
  (female jane)
  (male john)
  (parent :parent jane :child george)
  (parent :parent john :child george))

(defrule father-is-male-parent
  (male ?father)
  (parent :parent ?father :child ?child)
  =>
   (assert (father :father ?father :child ?child)))

(defrule mother-is-female-parent
  (female ?mother)
  (parent :parent ?mother :child ?child)
  =>
   (assert (mother :mother ?mother :child ?child))).
```

Zajímá-li nás, kdo je matkou George, můžeme zkusit spustit dopřednou inferenci. Po jejím skončení bude v pracovní paměti jak informace o Georgově matce, tak o jeho otci. Systém se tedy v tomto případě dobral správného výsledku, vypočítal ale i další fakty, které nás nezajímaly. Dokážeme si snadno představit, že ve větším programu může být výpočet všech odvoditelných závěrů velmi výpočetně a tudíž i časově náročný.

Spustíme-li naopak zpětnou inferenci voláním

```
(reset)
(defgoal (mother :mother ?mother-of-george :child george))
(back-run),
je výsledkem
```

```
All goals have been satisfied

(MOTHER (MOTHER . ?MOTHER-OF-GEORGE) (CHILD . GEORGE)) satisfied by

(RULE MOTHER-IS-FEMALE-PARENT

(FEMALE ?MOTHER)

(PARENT (PARENT . ?MOTHER) (CHILD . ?CHILD))

=>

(ASSERT (MOTHER :MOTHER ?MOTHER :CHILD ?CHILD)))

(FEMALE ?MOTHER) satisfied by (FEMALE JANE)

(PARENT (PARENT . JANE) (CHILD . GEORGE)) satisfied by

(PARENT (PARENT . JANE) (CHILD . GEORGE))

These variable bindings have been used:

((?MOTHER-OF-GEORGE . JANE)).
```

Systém tedy vyvodil pouze závěr, který nás zajímal.

No feasible answer found.

Zpětná inference umožnuje také výpočet alternativních odpovědí, tedy hledání dalších cest výpočtu (a vazeb proměnných), které vedou ke splnění všech cílů. Na další alternativní odpověď se dotážeme jednoduše opětovným voláním (back-run).

Zajímají-li nás například oba rodiče George, můžeme zadat cíl

```
(defgoal (parent :parent ?parent :child george)).
Pokud poté třikrát zavoláme (back-run), obdržíme výstup
All goals have been satisfied
(PARENT (PARENT . ?PARENT) (CHILD . GEORGE)) satisfied by
    (PARENT (PARENT . JANE) (CHILD . GEORGE))
These variable bindings have been used:
    ((?PARENT . JANE))

All goals have been satisfied
(PARENT (PARENT . ?PARENT) (CHILD . GEORGE)) satisfied by
    (PARENT (PARENT . JOHN) (CHILD . GEORGE))
These variable bindings have been used:
    ((?PARENT . JOHN))
```

Systém tedy najde obě možné odpovědi (vazby proměnných), vedoucí ke splnění cíle, načež oznámí, že další odpověď už neexistuje.

Zpětná inference nemění obsah pracovní paměti. To ani není možné vzhledem k tomu, že ve chvíli, kdy inference zvolí pravidlo, jehož důsledky vedou ke splnění aktuálního cíle, nejsou jeho podmínky často ještě splněny. Místo toho pracuje zpětná inference pouze s množinou cílů.

Jednotlivé cíle jsou postupně vybírány a hledají se cesty k jejich splnění. Inference nejprve zkoumá fakty v pracovní paměti. Není-li aktuální cíl splněn žádným z platných faktů, uvažuje dále jednotlivá pravidla. Najde-li pravidlo, které by po aktivaci vedlo ke splnění aktuálního cíle, naváže proměnné, použité v jeho důsledcích, podle vzoru cíle. Tyto vazby poté aplikuje na jeho podmínky (tedy opačně než u inference dopředné) a ty pak přidá do množiny cílů. Použité vazby proměnných se navíc aplikují i na zbytek cílů.

Zkusme nyní krokovat (použitím (back-step)) předchozí příklad s dotazem na matku George s průběžným výpisem cílů pomocí (goals).

```
GOALS: ((MOTHER :MOTHER ?MOTHER-OF-GEORGE :CHILD GEORGE))

(MOTHER (MOTHER . ?MOTHER-OF-GEORGE) (CHILD . GEORGE)) satisfied by

(RULE MOTHER-IS-FEMALE-PARENT

(FEMALE ?MOTHER)

(PARENT (PARENT . ?MOTHER) (CHILD . ?CHILD))

=>

(ASSERT (MOTHER :MOTHER ?MOTHER :CHILD ?CHILD)))

GOALS: ((FEMALE ?MOTHER) (PARENT :PARENT ?MOTHER :CHILD GEORGE))

(FEMALE ?MOTHER) satisfied by (FEMALE JANE)

GOALS: ((PARENT :PARENT JANE :CHILD GEORGE))

(PARENT (PARENT . JANE) (CHILD . GEORGE))
```

V prvním kroku je proměnná ?mother-of-george, použitá v definici cíle, nahrazena proměnnou ?mother, použitou v důslecích pravidla mother-if-female-parent. Proměnná ?child v důsledcích je navázána na george a touto vazbou jsou nahrazeny výskyty proměnné v podmínkách pravidla. Podmínky jsou poté přidány do množiny cílů. Původní cíl je poté z množiny odstraněn.

V druhém kroku je nový cíl (female ?mother) porovnán s faktem (female jane) v pracovní paměti, je jím splněn a v posledním cíli je proměnná ?mother navázána na jane. Tento cíl je pak v posledním kroku triviálně splněn identickým faktem.

Aktuální stav výpočtu pomocí zpětné inference je ztracen, zavoláme-li během krokování defgoal nebo undefgoal. Kdyby tomu tak nebylo, mohli bychom systém uvést do nekonzistentního stavu.

Implementace zpětné inference v ExiLu je velmi omezená. V důsledcích pravidel zohledňuje pouze specifikace faktů ve voláních assert. Nelze ji tedy aplikovat u pravidel, která fakty z pracovní paměti odstraňují, či je modifikují. Inference také neumí pracovat s negovanými cíli, tudíž ani s pravidly, která mají negované podmínky (neboť tyto by při použití pravidla mezi cíli objevily).

Použití zpětné inference nemusí nutně snížit míru nedeterminismu výpočtu. Existuje-li několik pravidel, která vedou ke splnění aktuálního cíle, bude výpočet opět nedeterministický. Na rozdíl od dopředné inference lze ale alternativní cesty výpočtu postupně prohledat. To je možné jednak díky backtrackingu - nevede-li daná cesta ke splnění všech cílů, výpočet se vrátí a zkusí se ubírat jinudy. Dále díky možnosti dotázat se na alternativní odpovědi.

2.3.9. Reset prostředí

Entitu, která uchovává aktuální stav systému, nazývám v ExiLu prostředím. Hodnoty tvořící aktuální stav prostředí rozděluji do dvou skupin. První skupinu tvoří hodnoty trvalé. Sem spadají definice šablon, znalostní báze (skupiny faktů, pravidla), definice strategií pro volbu shod a aktuálně zvolená strategie.

Druhou skupinou jsou hodnoty dočasné. Sem patří aktuální stav pracovní paměti, aktuální cíle, stav sítě RETE spolu s agendou udržující aktuální shody (splněná pravidla spolu s vazbami proměnných), hodnoty zásobníků sloužících k vrácení provedených akcí a jejich opětovné provedení (undo/redo) a hodnota zásobníku udržujícího aktuální stav zpětné inference (aby bylo možné ji krokovat nebo se dotázat na alternativní odpovědi).

Dočasné hodnoty lze uvést do výchozího stavu voláním (clear). Tím systém uvedeme do stavu, kdy zná pouze definované šablony, skupiny faktů a odvozovací pravidla. Volání (reset) provede (clear) následovaný zavedením všech skupin faktů do pracovní paměti. Všechny hodnoty prostředí, tedy včetně trvalých, lze pak uvést do výchozího stavu voláním (complete-reset).

Chování reset a clear vzhledem k zásobníkům pro vracení akcí může být poněkud překvapivé. Makro reset totiž vymaže obsah tohoto zásobníku, poté na něj však uloží akci k vrácení jeho volání. Z výpisu (undo-stack) tak po volání reset zmizí předchozí akce, uvidíme zde jen akci (reset). Po volání (undo) se na zásobníku předchozí akce opět objeví. Totéž platí pro volání (clear).

2.3.10. Práce s více prostředími

Při práci s ExiLem se nemusíme omezovat pouze na jedno prostředí (byť si s ním často vystačíme). Nové prostředí lze definovat voláním defenv s názvem prostředí, např. (defenv test). Prostředí pak lze přepnout voláním (setenv test), případně smazat voláním (undefenv test).

Každé prostředí má oddělený stav, tedy trvalé i dočasné hodnoty (viz předchozí sekce). Na název aktuálního prostředí se lze dotázat voláním (current-environment). Název výchozího prostředí je default. Seznam všech prostředí získáme voláním (environments).

Máme-li už definované prostředí, např. test, opětovné volání (defenv test) skončí výjimkou. Tím je zajištěno, že si omylem nevymažeme celé prostředí. Chceme-li jej opravdu vymazat, musíme volat (defenv test :redefine t).

2.3.11. Volání ExiLu z jiného kódu a naopak

definice šablon

Doposud jsem v ukázkách práce s ExiLem pracoval většinou s makry. Byla to následující:

deftemplate undeftemplate find-template definice skupin faktů deffacts undeffacts find-fact-group definice pravidel defrule undefrule find-rule modifikace pracovní paměti assert retract modify

definice cílů defgoal undefgoal

sledování průběhu inference watch unwatch watchedp

strategie výběru shody defstrategy setstrategy

definice prostředí defenv undefenv setenv

Tato makra berou jako parametry symboly a/nebo seznamy a tyto automaticky quotují. To je pohodlné, pracujeme-li s knihovnou přímo. Představme si ale, že chceme knihovnu volat z jiného kódu a například specifikace faktů, které předáváme makru assert, generovat nějakou funkcí.

Protože makro assert seznamy se specifikacemi faktů quotuje, místo aby je vyhodnotilo, nelze ho v tomto případě použít. Výsledkem volání

```
(assert (generate-fact))
```

totiž bude přidání faktu (generate-fact) do pracovní paměti. K tomuto účelu poskytuje ExiL ke všem uvedeným makrům funkční alternativy, které parametry vyhodnocují. Tyto jsou označeny suffixem f, například assertf. Tímto suffixem sice v Lispu typicky označujeme destruktivní makra, která mění svůj argument, v případě exilových maker ale záměna nehrozí.

Dotazovací funkce a makra jako facts, goals, find-fact-group, apod. navíc nevypisují hodnoty na výstup, nýbrž vrací externí reprezentaci objektů, se kterou je možné dále manipulovat a pak ji třeba systému předat zpátky. To umožnuje například následující (nepříliš užitečné) volání:

```
(dolist (fact (facts))
  (retractf fact)
  (assertf (cons 'my-fact fact))).
```

Funkční alternativy jako assertí také umožnují použití složitějších konstruktů v důsledcích pravidla. Bude-li například podmínka pravidla

```
(defrule surround-by-as
  (palindrome ?p)
=>
  (assertf '(palindrome ,(concatenate 'string "a" ?p "a"))))
```

splněna faktem (palindrome "b"), přibyde po jeho aktivaci do pracovní paměti fakt (palindrome "aba"). Funkci assertf bohužel nelze použít se zpětnou inferencí, neboť ta nemá šanci předvídat, jaký fakt bude jejím voláním do pracovní paměti přidán.

V důsledcích pravidla bychom také mohli chtít například upozornit jinou část programu na událost, ke které došlo. Protože ExiL nahrazuje výskyty proměnných v celé důsledkové části pravidla, lze toho snadno dosáhnout. Je ale třeba dát pozor na quotování hodnot proměnných. Uvažme pravidlo

```
(defrule move-robot
  (goal move robot ?from ?to)
  (in robot ?from)
  =>
  (retract (in robot ?from))
  (assert (in robot ?to))
  (notify 'moving-robot '?from '?to))
```

a fakt (goal move robot A B) v pracovní paměti. Kdybychom ve volání notify proměnné ?from a ?to nequotovali, volání by se při aktivaci pravidla vyhodnotilo jako (notify 'moving-robot A B). To by pravděpodobně skončilo chybovou hláškou sdělující, že proměnné A a B nejsou definovány.

Makra deftemplate, deffacts, defrule a modify berou specifikace slotů šablony, faktů, těla pravidla a změn k provedení (v tomto pořadí) jako další parametry. Díky tomu nemusíme tyto parametry obalovat do dalšího seznamu. Jejich funkční alternativy naproti tomu očekávají tyto parametry v jednom seznamu, například

```
(deffactsf 'world (list '(in box A) '(in robot B))).
```

To umožňuje snazší generování těchto specifikací funkcemi.

2.3.12. Kompatibilita se systémem CLIPS

Dalším z požadavků zadání práce bylo přiblížit syntax exilových volání systému CLIPS, aby bylo možné programy v něm napsané snáze převést na programy exilové. Toho se mi podařilo dosáhnout jen částečně.

Systém CLIPS použivá jiný formát specifikací slotů šablony, strukturovaných faktů a požadovaných změn při volání modify. Tuto syntax nyní ExiL podporuje také. Příklad 3 na straně 32 ukazuje definici znalostní báze ekvivalentní příkladu 2 s použitím CLIPSové syntaxe. Syntax je dostatečně odlišná na to, aby ji ExiL

rozpoznal, není tedy třeba syntaktický mód nijak přepínat. Díky tomu dokonce můžeme oba typy syntaxe kombinovat.

ExiL také po vzoru CLIPSu umožňuje omezit seznam vrácený voláním (facts) volitelnými číselnými parametry. První volitelný parametr udává index prvního faktu v seznamu (číslováno od 1). Druhý parametr udává index posledního faktu. Třetí parametr pak maximální počet vrácených faktů.

Makra assert a retract také nyní umožňují přidání či odebrání více faktů najednou. Makru retract lze navíc místo specifikací faktů k odstranění předat jejich číselné indexy v seznamu faktů. Obě možnosti lze dokonce kombinovat.

V podmínkách pravidel lze nyní také použít speciální proměnnou ? a navázání celého faktu na proměnnou pomocí operátoru <-, jak jsem již popsal v sekci 2.3.5.

CLIPS dále umožňuje specifikovat u slotu šablony datový typ. To považuji v dynamickém jazyce, jakým je Common Lisp, za zbytečné. CLIPS také nabízí několik vlastních funkcí a možnost definice nových, které pak lze používat v důsledcích pravidel. To nemá v ExiLu smysl, neboť můžeme použít vestavěné nebo uživatelsky definované funkce Lispu.

CLIPS navíc poskytuje možnost definovat některé sloty šablony jako multislot. Ve vzorech podmínek pravidel pak můžeme používat proměnnou \$?, která se naváže na jeden nebo více atomů multislotu, případně jednoduchého faktu. Dále je v podmínkách CLIPSu možné používat libovolně vnořené agregační funkce and, or, not a podobně. Ve vzorech podmínek CLIPSových pravidel lze také používat speciální proměnné, které se shodují jen s některými atomy, např. proměnná ?color&~red&~yellow se shoduje se všemi atomy, kromě red a yellow.

Tyto možnosti ExiL neposkytuje, neboť jejich implementace by vyžadovala přepsat velkou část algoritmu RETE, který podmínky pravidel vyhodnocuje, jak popíšu v sekci zabývající se implementací.

```
(deftemplate goal
      (slot action (default move))
      (slot object)
      (slot from)
      (slot to))
   (deftemplate in
      (slot object)
      (slot location))
10
   (deffacts world
11
     (in (object robot) (location A))
12
      (in (object box) (location B))
13
      (goal (object box) (from B) (to A))).
14
15
   (defrule move-robot
16
      (goal (action move) (object ?obj) (from ?from))
      (in (object ?obj) (location ?from))
18
     (- in (object robot) (location ?from))
     ?robot <- (in (object robot) (location ?z))</pre>
20
      (modify ?robot (location ?from)))
22
   (defrule move-object
24
      (goal (action move) (object ?obj) (from ?from) (to ?to))
25
     ?object <- (in (object ?obj) (location ?from))</pre>
26
     ?robot <- (in (object robot) (location ?from))</pre>
27
28
      (modify ?robot (location ?to))
29
      (modify ?object (location ?to)))
30
31
   (defrule stop
32
     ?goal <- (goal (action move) (object ?obj) (to ?to))</pre>
33
     (in (object ?obj) (location ?to))
34
     =>
35
     (halt))
```

Příklad 3: Definice znalostní báze s použitím CLIPSové syntaxe

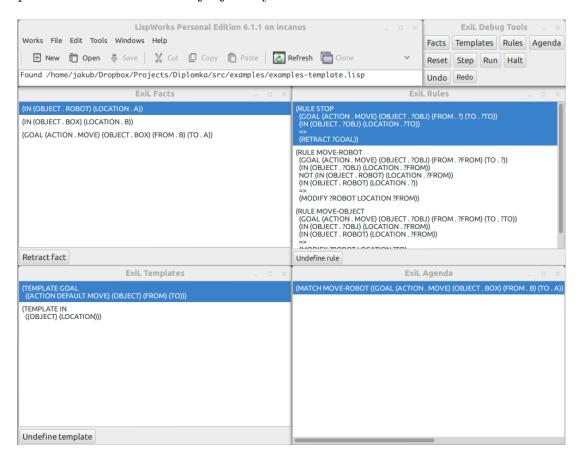
2.3.13. Grafické uživatelské rozhraní

Pro prostředí LispWorks jsem k ExiLu implementoval minimalistické grafické uživatelské rozhraní, zobrazené na obrázku 1. To sestává z hlavního okna s deseti tlačítky organizovanými do tří řad (vpravo nahoře).

První řada tlačítek - "Facts", "Templates", "Rules" a "Agenda" slouží k zobrazení podoken s jednotlivými položkami. Okno "Facts" zobrazuje seznam faktů v pracovní paměti a umožňuje jejich odebrání tlačítkem "Retract fact". Okno "Templates" zobrazuje seznam definovaných šablon a umožňuje jejich odebrání tlačítkem "Undefine template". Okno "Rules" zobrazuje seznam definovaných odvozovacích pravidel a umožňuje jejich odebrání tlačítkem "Undefine rule". Poslední okno "Agenda" zobrazuje seznam aktuálních shod v agendě. Seznamy v oknech se automaticky obnovují při každé změně zobrazených hodnot.

Druhá řada tlačítek - "Reset", "Step", "Run" a "Halt" umožňuje řízení inference. Tlačítka volají stejnojmenné funkce ExiLu.

Poslední řada tlačítek - "Undo" a "Redo" slouží k vracení a opětovnému provedení akcí voláním stejnojmenných funkcí ExiLu.



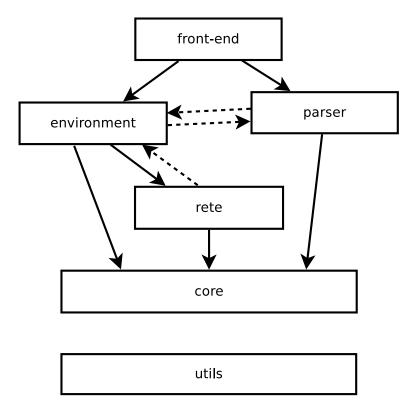
Obrázek 1. Grafické uživatelské rozhraní

Rozhraní lze zobrazit voláním (exil-gui:show-gui). Každé prostředí má vlastní rozhraní. Volání show-gui bez parametru zobrazí rozhraní k aktuálnímu prostředí. Jako volitelný parametr můžeme funkci předat název prostředí, jehož rozhraní chceme zobrazit. Máme-li tedy definováno více prostředí, můžeme si ke každému z nich zobrazit uživatelské rozhraní.

2.4. Implementace

2.4.1. Architektura programu

V následující sekci budu používat obecný pojem modul pro ohraničenou část programu, implementující nějakou část funkcionality. Veřejné rozhraní modulu definuje vstupní body, pomocí nichž s ním mohou ostatní moduly komunikovat. Ty jsou zde reprezentovány funkcemi, makry a metodami, které modul poskytuje a specifikacemi jejich parametrů. V Common Lispu sice tuto entitu nazýváme package, tento pojem se však špatně skloňuje a celkově narušuje plynulost textu.



Obrázek 2. Architektura ExiLu

Obrázek 2. zobrazuje architekturu knihovny ExiL, tedy moduly, do kterých je kód knihovny rozdělen a jejich vzájemnou komunikaci. Orientace šipek určuje směr volání funkcí (metod, maker) poskytovaných moduly, např. modul front-end volá funkce modulu parser a ne naopak. Těmito voláními jsou zároveň definovány závislosti mezi moduly, ty mají tedy stejnou orientaci.

Modul utils definuje různorodé pomocné funkce a makra, která jsou volána všemi ostatními moduly. V obrázku 2. bych tedy mohl zahrnout šipky ze všech ostatních modulů do modulu utils, to by jej však činilo zbytečně nepřehledným. Většina funkcí a maker, která modul definuje, usnadňuje nízkoúrovňovou práci se

symboly a datovými strukturami - (asociativními) seznamy, množinami, stromy, hashovacími tabulkami apod.

Modul **core** definuje základní objekty, s nimiž zbytek knihovny pracuje. Ty reprezentují fakty, vzory, šablony a pravidla. Fakty a vzory jsou definovány ve dvou variantách - jednoduché a strukturované (*templated*), jak jsem uvedl v uživatelské příručce.

Modul rete implementuje algoritmus RETE, který slouží k efektivnímu vyhodnocování podmínek odvozovacích pravidel. Algoritmus je implementován dataflow sítí, jejíž fungování popíšu detailně v sekci 2.4.2. Algoritmus RETE je sice nejkomplexnější částí ExiLu, veřejné rozhraní modulu rete je však velmi jednoduché.

Modul poskytuje dvojici metod kterými síť RETE upozorníme na přidání nebo odebrání pravidel. Ty dle potřeby doplní síť o uzly potřebné k vyhodnocení podmínek těchto pravidel, případně uzly při odebrání pravidla odstraní.

Další dvojice metod upozorní síť na přidání faktu do (resp. odebrání z) pracovní paměti. Síť pak přepočítá splněné podmínky pravidel a případně upozorní prostředí na nově přibyvší nebo rozbité shody (broken match - pravidla, která byla splněná a už nejsou).

Modul environment definuje stejnojmenný objekt, který udržuje průbežný stav prostředí a řídí průběh inference. Hodnoty, které stav prostředí tvoří, jsem popsal v sekci 2.3.9. Prostředí udržuje krom jiného referenci na síť rete, kterou upozorňuje na nastalé změny.

Modul parser zajišťuje vytváření core objektů z externí reprezentace (té, kterou předáváme makrům při práci s knihovnou). Modul rozpoznává jak základní, tak CLIPSovou syntax, takže o to, kterou z nich uživatel používá se zbytek kódu nemusí dále starat.

Při parsování strukturovaných faktů či vzorů se parser dotazuje aktuálního prostředí na definici šablony. Při zpětné inferenci prostředí vyhodnocuje volání assert v důsledcích pravidel a žádá parser o zparsování reprezentací faktů v nich. Proto jsem mezi moduly environment a parser přidal šrafované šipky. Kromě těchto nutných interakcí spolu však moduly nekomunikují.

Modul front-end udržuje seznam definovaných prostředí a ví, které je právě aktivní. Kromě manipulace tohoto seznamu modul sám žádnou funkcionalitu neimplementuje. Pouze quotuje parametry předané makrům, předává je parseru a výsledné objekty (se zbytkem parametrů) pak aktivnímu prostředí.

Do diagramu jsem nezahrnul modul gui. Ten implementuje grafické uživatelské rozhraní a poskytuje jedinou metodu - show-gui. Rozhraní se dotazuje prostředí, se kterým je svázáno, na hodnoty aktuálního stavu a je jím upozorněno, pokud se tyto změní.

2.4.2. Algoritmus RETE

Algoritmus RETE slouží k efektivnímu vyhodnocování splnění podmínek odvozovacích pravidel (dále jen vyhodnocování). Je implementován dataflow sítí. Ta je rozdělena do dvou částí, označovaných jako alpha a beta. Alpha část sítě vyhodnocuje splnění jednotlivých podmínek pravidla fakty nově přidanými do či odebranými z pracovní paměti. Beta část pak zajišťuje zachování konzistence vazeb proměnných mezi podmínkami.

To, že je vyhodnocování sítí RETE tak efektivní, je zajištěno maximálním sdílením častí sítě mezi pravidly. Mají-li dvě pravidla strukturálně stejný vzor nějaké podmínky (liší se jen použité proměnné), sdílí tato pravidla část alpha sítě, která tuto podmínku vyhodnocuje. Pokud mají dvě pravidla stejných několik prvních podmínek, sdílí tato pravidla kromě části alpha sítě i část beta sítě, která zajišťuje konzistenci vazeb proměnných mezi nimi. Čím více je v systému definováno odvozovacích pravidel, tím pravděpodobnější jsou shody mezi jejich podmínkami a tím více se efektivita algoritmu projeví.

Dataflow síť tvoří orientovaný acyklický graf²¹. Uzly sítě rozdělujeme na dva základní typy - paměťové a testovací. Paměťové uzly ukládají průběžné výsledky vyhodnocování. Testovací uzly provádějí různé typy testů (v závislosti na typu uzlu) nutných pro vyhodnocení podmínek pravidla.

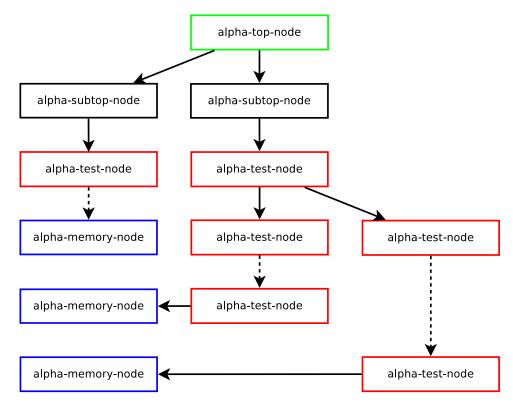
Mezi uzly sítě dochází ke dvěma typům interakcí. Hlavním typem interakce je aktivace. Ta probíhá ve směru hran grafu a uzel při ní provádí svou hlavní funkci v závislosti na typu. Testovací uzel se dále může dotazovat sousedního paměťového uzlu na obsah jeho paměti a to **proti směru orientace hran**. Abych odlišil sousední uzly ve směru hran (tedy ty, jež může uzel aktivovat) od množiny všech sousedů, budu první skupinu nazývat *potomky*.

Uzlu je při aktivaci vždy předána nějaká datová struktura. Tou je buď fakt, nebo token, který reprezentuje posloupnost faktů. Zatímco paměťové uzly po aktivaci a uložení datové struktury do své paměti vždy aktivují své potomky, testovací uzly aktivují potomky jen v případě úspěšného testu.

Obrázek 3. zobrazuje úsek alpha části sítě RETE. Uzel alpha-top-node je vstupním bodem této sítě. Ten je aktivován při každé změně pracovní paměti faktem, který byl přidán nebo odebrán. Potomky alpha-top-nodu jsou alpha-subtop-nody, jeden pro jednoduché fakty a jeden pro každou definova-nou šablonu. Alpha-top-node aktivuje příslušný alpha-subtop-node podle typu faktu. Ten pak aktivuje alpha-test-node pod ním.

Srafované šipky v obrázku 3. symbolizují, že zde může následovat posloupnost několika dalších alpha-test-nodů. Každá cesta z alpha-subtop-nodu do alpha-memory-nodu skrze posloupnost alpha-test-nodů vyhodnocuje jednu podmínku nějakého pravidla (případně skupiny pravidel). Mějme například pravidla

²¹http://en.wikipedia.org/wiki/Directed_acyclic_graph

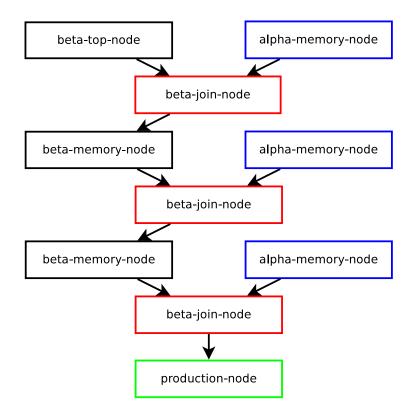


Obrázek 3. Alpha část sítě RETE

```
(defrule rule1
  (in :object box :location ?locaction)
  =>
    ...)
(defrule rule2
  (in :object box :location ?loc)
  =>
    ...).
```

Tato pravidla mohou sdílet část alpha sítě pro vyhodnocení svých podmínek, neboť ty se liší pouze názvy proměnných. Pro vyhodnocení těchto podmínek budeme potřebovat jeden alpha-subtop-node pro šablonu in, jeden alpha-test-node pro testování, zda je hodnota slotu object rovna hodnotě box a jeden alpha-memory-node pro uložení faktů, které tuto podmínku splňují. Pro slot location alpha-test-node nepotřebujeme, neboť alpha část sítě se hodnotami proměnných nezabývá.

Obrázek 4. zobrazuje úsek beta části sítě, spolu s alpha-memory-nody, kterými sem vstupují fakta splňující jednotlivé podmínky pravidel. Každý beta-memory-node udržuje množinu tokenů reprezentujících posloupnosti faktů, z nichž každý splňuje podmínku nějakého pravidla. Beta-join-nody pak tes-



Obrázek 4. Beta část sítě RETE

tují konzistenci vazeb proměnných mezi těmito podmínkami. beta-top-node je speciální typ beta-memory-nodu, který udržuje v paměti pouze jeden prázdný token. production-node je pak speciální typ beta-memory-nodu, který při aktivaci upozorní prostředí, že byly splněny všechny podmínky pravidla, případně že po odstranění faktu už nejsou všechny splněny.

Mějme například pravidlo

```
(defrule rule
  (goal :object ?obj :from ?from :to ?to)
  (in :object ?obj :location ?from)
  (in :object robot :location ?to)
  =>
  ...).
```

Alpha část sítě pro toto pravidlo bude obsahovat tři alpha-memory-nody, každý pro jednu jeho podmínku (kdyby však byla v poslední podmínce místo hodnoty robot proměnná, vystačili bychom si se dvěma alpha-memory-nody).

Beta část sítě bude vypadat tak, jako na obrázku 4. První (shora) beta-test-node ve skutečnosti nemá co testovat, neboť jde o první podmínku pravidla. První beta-memory-node bude udržovat tokeny délky 1 reprezentující "posloupnost" faktů, které splňují první podmínku. Druhý beta-join-node

bude testovat konzistenci vazeb mezi druhou a první podmínkou pravidla. Druhý beta-memory-node bude udržovat tokeny délky 2 reprezentující dvojice faktů, splňující první dvě podmínky pravidla. Třetí beta-join-node bude testovat konzistenci vazeb mezi třetí podmínkou pravidla a předchozími dvěma. Production-node pak bude udržovat tokeny délky 3 reprezentující trojice faktů splňující všechny podmínky pravidla.

Přidávejme nyní postupně fakty do pracovní paměti. Přidáním (in :object box :location A) dojde (po průchodu alpha částí sítě) k aktivaci druhého alpha-memory-nodu. Ten uloží fakt do své paměti a aktivuje "zprava" druhý beta-join-node. Ten prohledá paměť beta-memory-nodu nad sebou, zda neobsahuje nějaký token s konzistentními vazbami proměnných. Ta je ale prázdná, takže zde se aktivace zastaví.

Přidáním (goal :object box :from A :to B) dojde k aktivaci prvního alpha-memory-nodu. Ten po uložení faktu aktivuje první beta-join-node. Ten nemá co testovat, takže aktivuje beta-memory-node pod sebou. Ten uloží jednoprvkový token s přidaným faktem a aktivuje opět druhý beta-join-node, tentokrát však "zleva". Beta-join-node tentokrát prohledá obsah paměti alpha-memory-nodu nad sebou, zda neobsahuje fakt konzistentní s tokenem. Beta-join-node zde testuje, zda jsou hodnoty slotů object a location faktu v alpha paměti shodné s hodnotami object a from prvního faktu tokenu v beta paměti.

Test zde skončí úspěšně, takže druhý beta-join-node aktivuje beta-memory-node pod sebou a předá mu dvouprvkový token s oběma fakty. Ten aktivuje "zleva" třetí beta-join-node. Ten následně prohledá paměť alpha-memory-nodu nad sebou. Ta je ale prázdná, takže zde aktivace skončí.

Po přidání faktu (in :object robot :location B) dojde k aktivaci třetího alpha-memory-nodu. Ten fakt uloží a aktivuje "zprava" třetí beta-join-node. Ten prohledá paměť beta-memory-nodu nad sebou, zda neobsahuje konzistentní tokeny. Ta obsahuje dvouprvkový token s prvními dvěma fakty. Beta-join-node tedy srovná hodnotu slotu location přidaného faktu s hodnotou slotu to prvního faktu tokenu. Protože tyto hodnoty se shodují, aktivuje beta-join-node production-node pod sebou a předá mu tříprvkový token s posloupností faktů, které splňují všechny podmínky pravidla. Ten token uloží a upozorní prostředí, že pravidlo bylo splňeno posloupností faktů v tokenu.

Jak jsme viděli, beta-join-node může být aktivován buď zprava alpha-memory-nodem s novým faktem, který splňuje nějakou podmínku pravidla, nebo zleva beta-memory-nodem s tokenem, jehož fakty splňují předchozí podmínky. V každém případě beta-join-node prohledá obsah paměti druhého paměťového uzlu nad ním, aby nalezl tokeny konzistentní s novým faktem, nebo fakty konzistentní s novým tokenem.

Speciálním typem beta-join-nodu je beta-negative-node, který je zprava aktivován alpha-memory-nodem udržujícím fakty, které splňují negovanou podmínku pravidla. Ten naopak testuje, že druhá paměť neobsahuje konzistentní

fakty/tokeny a v takovém případě aktivuje potomky.

Při odebrání faktu z pracovní paměti se síť chová velmi podobně. Paměťové uzly ale v tomto případě odebírají fakty/tokeny ze svých pamětí. Je-li při odebrání faktu aktivován production-node, upozorní prostředí, že pravidlo už není původní posloupností faktů splněno.

Odlišně se ovšem při odebrání faktu chovají beta-negative-nody. Každý beta-negative-node je potomkem dvou paměťových uzlů - jed-noho beta-memory-nodu a jednoho alpha-memory-nodu. Pokud byl odebíraný fakt/token v paměti jednoho z těchto paměťových uzlů jediným faktem/tokenem, konzistentním s fakty/tokeny v druhém paměťovém uzlu, je nyní negovaná podmínka pravidla splněna a beta-negative-node aktivuje beta-memory-node pod sebou všemi tokeny z paměti beta-memory-nodu nad sebou, jako by šlo o nově přidané tokeny.

Kdybychom nyní přidali pravidlo, které má první dvě podmínky stejné jako předchozí pravidlo, většina beta části sítě by zůstala stejná. Druhý beta-memory-node by ale získal jako potomka další beta-join-node, který by testoval konzistenci vazeb proměnných ve třetí, odlišné podmínce vůči prvním dvěma. Pod ním by pak následovaly další uzly testující zbytek podmínek a nový production-node. Kdybychom přidali pravidlo, které má všechny podmínky stejné, síť by se dokonce nezměnila vůbec. Původní production-node by si jen zapamatoval, že jeho aktivace nyní značí splnění obou pravidel.

Každý typ uzlu sítě RETE je v programu reprezentován jedním typem objektu stejného názvu. Každý z těchto objektů implementuje metodu activate, jejímž zavoláním je uzel aktivován. Většina kódu implementujícího modul rete je tvořena právě definicemi metod activate. Další část kódu pak implementuje dotváření sítě při přidání pravidla, které je netriviální. Program zde prochází podmínky pravidla, přičemž zároveň postupuje v síti odshora a zkoumá, zda je třeba vytvářet nové uzly, nebo lze použít existující, případně je nově propojit.

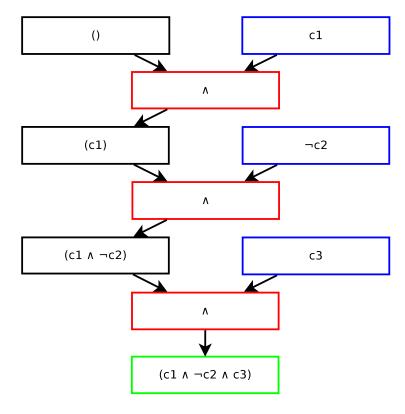
Teorii potřebnou k implementaci algoritmu RETE jsem nastudoval z [4].

2.4.3. Kompozitní podmínky pravidel

Podporu kompozitních podmínek odvozovacích pravidel (vnořené aplikace logických funkcí v podmínkách) jsem v ExiLu neimplementoval. Rád bych zde ale ukázal, proč je implementace této funkcionality vzhledem k aktuální implementaci algoritmu RETE složitá.

Obrázek 5. ukazuje diagram beta části sítě RETE z předchozí sekce. Názvy uzlů jsem zde ale nahradil jejich funkcí. Paměťové uzly ukládají fakty nebo tokeny splňující jednu (v případě alpha-memory-nodů), nebo více (u beta-memory-nodů) podmínek pravidla. Testovací (beta-join-nody) pak zajišťují agregaci těchto faktů a tokenů. Jednu z podmínek jsem navíc pro ukázku znegoval.

Síť v diagramu splňuje několik podmínek:

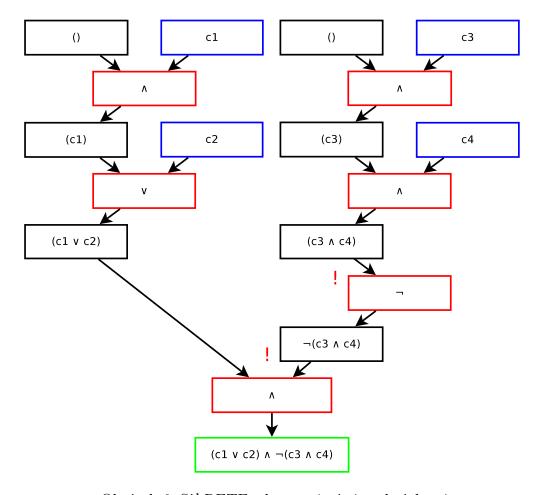


Obrázek 5. Beta část sítě RETE s funkcemi uzlů

- 1. uzly jsou konstruovány ve stejném pořadí, v jakém se podmínky v definici pravidla vyskytují,
- 2. beta-join-node vždy spojuje jeden alpha-memory-node s jedním betamemory-nodem, agreguje tedy fakty splňující jednu podmínku pravidla s tokeny reprezentujícími posloupnost faktů splňující jeho předchozí podmínky,
- 3. negace podmínky je vždy aplikována jen na úrovni jednoho faktu.

Představme si nyní stavbu RETE sítě v případě následujícícho pravidla s kompozitními podmínkami:

Ta je zobrazena na obrázku 6. Z diagramu vidíme, že síť porušuje všechny uvedené podmínky.



Obrázek 6. Síť RETE s kompozitními podmínkami

- popsat, co je problematického na podpoře této sítě
- podmínky třeba procházet rekurzivně a síť budovat stromovitě
- token je nyní list, stačí to, nebo musí být také strom?
- testy v join nodech nyní ukládají pozici o kolik podmínek zpět, který atom v přechozí, který atom v aktuální
- pozice by musela mít u beta-beta joinu minimálně jednu pozici navíc (fakt,atom)-(fakt,atom), pokud by musel být token strom, ještě složitější
- lze vyřešit join-nody obecně beta-beta i beta-alpha, nebo nutné dva typy?
- jak reprezentovat node, který neguje složenou podmínku?

- jak joinovat tokeny, které mohou zahrnovat výsledky negativní podmínky?
- síť je cyklická a jako taková špatně vizualizuje
- počet uzlů sítě roste velmi rychle → mnoho uzlů i při několika pravidlech
 → náročné ladění
- podpora kompozitních podmínek je navíc problematická vzhledem ke zpětné inferenci (ale ta už je stejně omezená) - znamenalo by složené cíle (kvůli or, not)
- zmínit, jak jednoduchá je implementace, pokud podmínky pracují pouze se substitucemi proměnných - bez rete

2.4.4. Undo/redo

Možnost vrácení provedených akcí a jejich opětovného provedení (undo/redo) je implementována na úrovni prostředí, které udržuje aktuální stav systému. Hodnoty, které stav tvoří, jsem popsal v sekci 2.3.9. a možnosti, které undo/redo poskytuje, v sekci 2.3.7.

Prostředí je v programu reprezentováno objektem **environment**. Stav systému je uchováván ve slotech tohoto objektu.

Prostředí dále udržuje dva zásobníky - undo a redo. Každý z těchto zásobníků ukládá seznamy tvořené popiskem akce k vrácení, uzávěrem, který akci vrátí a uzávěrem, který ji opět provede. První uzávěr ve svém lexikálním prostředí uchovává hodnoty potřebné k vrácení akce. Zásobníky jsou manipulovány pouze několika makry a metodami k tomu určenými, zbytek kódu k zásobníkům přímo nepřistupuje.

Tělo každé akce, která mění hodnoty prostředí, je obaleno buď voláním makra with-undo, nebo with-saved-slots. Volání with-undo je kromě těla akce předán uzávěr, který zajistí její vrácení. Makro with-undo po vyhodnocení těla akce zajistí, že se na zásobník undo uloží předaný uzávěr spolu s uzávěrem, který akci opět provede při volání redo. Tento druhý uzávěr pouze vyhodnotí původní tělo akce.

Makro with-saved-slot zjednodušuje volání with-undo. Toto makro bere kromě těla akce seznam slotů prostředí, které je třeba před akcí uložit. Makro pak automaticky vytvoří uzávěr, který předá makru with-undo. Tento uzávěr si ve svém lexikálním prostředí pamatuje kopie původních hodnot požadovaných slotů prostředí a při vyhodnocení je nastaví zpět na tyto hodnoty.

Prostředí ke každému svému slotu definuje metodu copy-<slot>, např. copy-facts. Makro with-saved-slots tedy vytvoří potřebný uzávěr tak, že

v letu naváže výsledky volání těchto metod pro každý požadovaný slot. V tomto letu pak vytvoří anonymní (lambda) funkci, která hodnoty prostředí nastaví zpět na ty, které let navázal.

Funkce undo pak jednoduše odstraní seznam z vrcholu zásobníku undo, zavolá uzávěr, který vrátí poslední akci a druhý uzávěr, který akci opět provede, uloží na vrchol zásobníku redo. Funkce redo funguje symetricky.

Všechny objekty definované modulem core - šablony, fakty, vzory a pravidla jsou implementovány jako neměnné (*immutable*). Každá jejich případná změna tedy znamená vytvoření nového objektu. Díky tomu není na úrovni prostředí nutné tyto objekty kopírovat. Kopírovat je třeba pouze datové struktury, které udržují kolekce těchto objektů.

Nakonec je třeba zajistit, aby každé volání with-undo uložilo na zásobník právě jeden uzávěr k vrácení akce. Například pokud samostatně voláme makro assert pro přidání nějakého faktu do pracovní paměti, chceme, aby toto volání bylo možné vrátit. Pokud ale voláme step, jehož výsledkem je aktivace nějakého pravidla, které ve svých důsledcích volá makro assert, chceme, aby se volání step uložilo na zásobník jako jedna akce. Volání assert, ke kterému v průběhu této akce dojde, už samostatně ukládat nechceme.

K tomuto účelu definuje prostředí dynamickou proměnnou *undo-enabled*. Makro with-undo ukládá uzávěr na zásobník jen v případě, že je hodnota této proměnná true. Tělo akce pak makro vyhodnocuje s hodnotou této proměnné navázanou na false. Tím je zajištěno, že se uzávěr na zásobník undo uloží vždy jen v "nejvnějšnějším" volání makra with-undo.

Díky makrům with-undo a with-saved-slots je možné velmi snadno přidat do prostředí další akce s možností jejich vrácení. Stačí jen tělo akce obalit jedním z těchto maker bez nutnosti vědět, jak je vrácení akce implementováno. Pokud potřebujeme do prostředí přidat další slot, jehož hodnotu je třeba při volání undo obnovovat, stačí k tomuto slotu implementovat metodu copy.

Nejsložitějším problémem při implementaci undo/redo bylo implementovat metodu copy-rete. Ta kopíruje dataflow síť RETE uloženou ve slotu rete prostředí. Kopírovnání sítě RETE je složité, neboť síť obsahuje cykly. Síť se sice z pohledu aktivace uzlů chová jako acyklický graf, některé uzly však uchovávájí reference na své sousedy proti směru hran tohoto grafu.

Pro účely kopírování sítě RETE jsem implementoval obecnou funkci vyššího řádu²² pro průchod cyklickým grafem. Tato funkce využívá techniky memoizace²³. Funkce bere kromě výchozího uzlu grafu tři funkce, které aplikuje na navštěvované uzly před memoizací a jimiž agreguje hodnoty vrácené sousedy uzlu.

Fungování funkce je pro textový popis příliš složité, považuji ji však za jednu z nejzajímavějších částí nového kódu, hlavně díky její obecnosti. Zrojový kód funkce je v souboru rete/graph-traversal.lisp, kód kopírující síť rete, který

²²http://en.wikipedia.org/wiki/Higher-order_function

²³http://en.wikipedia.org/wiki/Memoization

funkci využívá pak v souboru rete/rete-copy.lisp. Celkově je kód zajišťující kopírování sítě RETE asi třikrát delší, než zbytek kódu implementující funkcionalitu undo/redo. Ten se nachází v souboru environment/env-undo.lisp.

2.4.5. Zpětná inference

Zpětná inference hledá odpovědi na základě zadaných cílů. Odpovědi jsou zde reprezentovány použitou substitucí proměnných v cílech a posloupností faktů a pravidel, použitých k jejich splnění. Možnosti zpětného řetězení a způsob jeho použití jsem popsal v sekci 2.3.8.

Kód implementující zpětnou inferenci pracuje se dvěma datovými strukturami - seznamem cílů a zásobníkem pro backtracking (návrat ve výpočtu, pokud daná cesta nevede ke splnění všech cílů, nebo pro hledání alternativních odpovědí). Program nemodifikuje pracovní paměť, ani nevyhodnocuje odvozovací pravidla, pouze analyzuje volání assert v jejich důsledcích.

Cíle jsou v programu reprezentovány vzory, podobně jako podmínky pravidel. Inferenci si tedy můžeme představit tak, jako bychom definovali jedno pravidlo, jehož podmínky reprezentují seznam cílů a hledali všechny možné cesty výpočtu, vedoucí k jeho splnění.

Zásobník pro backtracking (dále jen zásobník) ukládá struktury, z nichž každá reprezentuje právě provedený krok výpočtu. Tato struktura je tvořen aktuálním seznamem cílů, faktem či pravidlem, použitým pro splnění aktuálního cíle a seznamem faktů a pravidel, která již byla pro splnění tohoto cíle použita (v případě návratu výpočtu).

Zpětná inference je řízena třemi metodami prostředí - back-step, backtrack a back-run. Metoda back-step vybere první cíl ze seznamu a hledá nejprve fakta, poté pravidla, vedoucí k jeho splnění, přičemž ignoruje ta, která už byla pro splnění cíle dříve použita.

Při hledání faktů, která splňují cíl, srovnáváme fakt se vzorem cíle podobně, jako při vyhodnocování podmínek pravidel při dopředné inferenci (viz sekce 2.3.5.). Výsledkem tohoto srovnání je v případě shody substituce proměnných, vyskytujících se ve vzoru cíle. Je-li nalezen fakt, který aktuální cíl splňuje, program uloží nalezenou shodu na zásobník, načež cíl odstraní ze seznamu cílů a aplikuje použitou substituci proměnných na zbytek cílů. Není-li nalezen takový fakt, uvažuje program dále odvozovací pravidla.

Při hledání pravidel, která vedou ke splnění aktuálního cíle, program zohledňuje všechna volání assert v jejich důsledcích. Reprezentace faktů, použité ve voláních assert, nechá program zpracovat parserem a výsledné fakty pak srovnává se vzorem cíle podobně, jako fakty v pracovní paměti. Protože jde však o důsledkovou část pravidla, volání assert mohou obsahovat proměnné. Program tedy hledá unifikaci aktuálního cíle s tímto "proměnným faktem".

V případě shody je výsledkem unifikace opět substituce proměnných. Program v tomto případě opět uloží shodu na zásobník, odstraní aktuální cíl ze seznamu

a aplikuje použitou substituci proměnných na zbytek cílů. Nejpreve ale program přidá podmínky použitého pravidla do seznamu cílů. Podmínky použitého pravidla se tedy stávají dalšími cíli, které je třeba splnit, abychom nalezli hledanou odpověď.

Hledání unifikace vzoru cíle s "proměnným faktem" je podobné jako v jazyce Prolog. Je však jednodušší o to, že symbolická reprezentace faktů a vzorů je lineární (seznamy nejsou vnořené) a není třeba rozlišovat mezi relačními a funkčními symboly. V případě strukturovanch faktů a vzorů jsou jednotlivé sloty srovnávány, jako by šlo o atomy seznamu, jen zde nezáleží na pořadí, nýbrž se srovnávají odpovídající sloty faktu a vzoru.

Pokud metoda back-step nenalezne fakt ani pravidlo vedoucí ke splnění aktuálního cíle, volá metodu backtrack. Ta odstraňuje postupně struktury z vrcholu zásobníku, obnoví cíle do stavu při uložení struktury a hledá shody s dosud nepoužitými fakty a pravidly. Pokud takovou shodu nalezne, ubírá se výpočet dále touto cestou. Je-li celý zásobník vyčerpán před nalezením shody, nahlásí metoda neúspěch.

Metoda back-run volá opakovaně metodu back-step, dokud nejsou splněny všechny cíle, nebo není nahlášen neúspěch. V případě, že už jsou všechny cíle splněny, volá back-step metodu backtrack pro nalezení alternativních odpovědí. To může vést k nalezení nové shody, nebo vyčerpání zásobníku, což znamená, že už žádné další odpovědi neexistují.

Dospěje-li volání back-run ke splnění všech cílů, vytiskne se seznam faktů a pravidel, použitých ke splnění jednotlivých cílů. Dále se vytiskne substituce proměnných, která byla pro splnění cílů použita. Tato substituce je tvořena složením všech substitucí, použitých v jednotlivých krocích výpočtu. Ve výsledné substituci jsou ponechány pouze proměnné, které uživatel použil v definicích původních cílů. Průběžné proměnné, které se sem dostaly při aplikaci odvozovacích pravidel, nejsou pro uživatele zajímavé.

Implementace zpětné inference nevyužívá sítě RETE, neboť ta vyhodnocuje splnění podmínek odvozovacích pravidel fakty v pracovní paměti. Zpětná inference ale pracuje opačně - analyzuje důsledky pravidel a pracovní paměť nemodifikuje. Síť RETE tedy nelze k implementaci využít.

Implementace je inspirována prohledáváním SLD-stromů používaným v jazyce Prolog²⁴. Z toho také vyplývají její omezení. Implementace pracuje pouze s "pozitivní znalostí" - neumožňuje zadání negativních cílů, ani negované podmínky pravidel. Implementace také uvažuje pouze přidání nových faktů v důsledcích pravidel, nikoli jejich odebrání nebo změnu. Díky tomu, že se důsledky pravidel nevyhodnocují, nedochází navíc k vedlejším efektům jako při dopředné inferenci.

Uvažovat negativní cíle, negované podmínky pravidel a odebírání faktů v důsledcích pravidla se na první pohled nezdá implementačně náročné. Nabízí se několik možností, kterak vyhodnocovat odebrání faktu v důsledcích pravidla, každá

²⁴http://en.wikipedia.org/wiki/SLD_resolution#SLD_resolution_strategies

z nich však vede k určitému typu problémů.

První možností je zohledňovat volání **retract** v důslecích pravidla jen jako indikaci, že toto pravidlo vede ke splnění negativního cíle, jinak je ignorovat. Zde ovšem hrozí problém, že důsledky některého z pravidel zneplatní podmínky dalšího. Uvažujme následující zadání:

```
(defgoal (at home))
(deffacts initial
  (out of city)
  (have money))
(defrule take-bus-to-city
  (have money)
  (out of city)
  =>
   (assert (at city))
  (retract (have money)))
(defrule take-taxi-home
  (have money)
  (at city)
  =>
   (assert (at home))
  (retract (have money)).
```

Dopředná inference v tomto případě korektně selže v odvození faktu (at home), neboť aplikace pravidla take-bus-to-city odstraní fakt (have money), tudíž druhé pravidlo už nemůže být splněno. Zpětná inference by však postupovala následovně:

```
;=> ((at home))
(goals)
(back-step) ; use rule take-taxi-home
(goals)
            ;=> ((have money) (at city))
(back-step); use fact (have money)
             ;=> ((at city))
(goals)
            ; use rule take-bus-to-city
(back-step)
             ;=> ((have money) (out of city))
(goals)
(back-step); use fact (have money)
(goals)
            ; => ((out of city))
(back-step)
            ; use fact (out of city)
            ;=> () => solution found
(goals)
```

Nalezeným řešením je tedy postupná aplikace pravidel take-bus-to-city a

take-taxi-home (zpětná inference je aplikuje v opačném pořadí), přestože toto řešení je nesprávné.

Další možností, která se nabízí, je pamatovat si všechny cíle, které se někdy vyskytovaly v množině cílů a brát volání (retract (have money)) v důsledcích pravidla jako indikaci, že pravidlo nelze použít, pokud je cíl (have money) v této množině. To sice řeší předchozí problém, ale vede k dalšímu. Představme si, že bychom do znalostní báze přidali pravidlo, které umožňuje použití bankomatu:

```
(defrule use-atm
  (have card)
  (have money on account)
=>
  (assert (have money))
  (retract (have money on account))).
```

Dopředná inference tentokrát nalezne korektní řešení postupnou aplikací pravidel take-bus-to-city, use-atm, take-taxi-home. Zpětná inference však selže, neboť pravidlo take-bus-to-city není díky tomuto způsobu vyhodnocování retract nikdy aktivováno.

Z neúspěchu předchozích variant je evidentní, že volání retract musí nějakým způsobem manipulovat množinu faktů. V jakou chvíli by k tomu ale mělo docházet? Pokud bychom fakt (have money) odstranili hned při aplikaci pravidla take-taxi-home (které zpětná inference uvažuje jako první), zneplatníme tím jeho vlastní podmínky. Po splnění všech jeho podmínek je už ale na odstraňování faktu pozdě, neboť to už bude aplikováno i pravidlo take-bus-to-city, k čemuž by vůbec dojít nemělo.

K podobným problémům bude docházet při zneplatnění negativního cíle (který se do množiny cílů může dostat také jako negovaná podmínka aplikovaného pravidla) voláním assert. Volání modify dokonce tato dvě spojuje. I kdybychom navíc našli vhodný způsob, kterak množinu faktů zpětně manipulovat, možnost backtrackingu by vyžadovala ukládat průběžné množiny faktů na zásobník, který by ve větších systémech rostl neúměrně rychle. Implementace plnohodnotného zpětného řetězení tedy není tak jednoduchá, jak se na první pohled jeví a domnívám se, že spolu s ostatními body zadání je nad rámec práce.

2.4.6. Kompatibilita se systémem CLIPS

Syntaktickou kompatibilitu se systémem CLIPS zajišťuje nově přidaný modul parser. Ten převádí externí reprezentace objektů - šablon, faktů, vzorů a pravidel - na interní objekty (ve smyslu instance třídy) definované v modulu core. K tomuto účelu definuje parser metodu parse-<object> pro každý typ core objektu. Externími reprezentacemi jsou (případně vnořené) seznamy symbolů, které předáváme funkcím a makrům modulu front-end, jež jsem popsal v uživatelské příručce.

Metody parseru jednoduše analyzují tyto seznamy, rozhodují, zda jde o základní, nebo CLIPSovou syntax a podle toho je převádí na jednotnou reprezentaci, kterou pak předávají konstruktorům core objektů. Tyto vnitřní objekty jsou pak metodami parseru vraceny. Metody jsou volány modulem front-end, který pak získané core objekty předává prostředí.

2.4.7. Grafické uživatelské rozhraní

Grafické uživatelské rozhraní je implementováno použitím knihovny CAPI²⁵. Program definuje pět rozhraní (oken) voláním makra define-interface knihovny. Každé rozhraní je pak reprezentováno objektem interface.

Každý z objektů rozhraní udržuje referenci na prostředí, s nímž je rozhraní svázáno a implementuje callbacky pro každé ze zobrazených tlačítek. Tyto callbacky pak volají příslušné funkce prostředí. Objekty rozhraní, která zobrazují seznamy hodnot prostředí, navíc implementují metodu update-lists, která slouží k překreslení seznamů a dotazuje se prostředí na jejich obsah.

Každé prostředí také udržuje referenci na rozhraní, které je s ním svázáno a upozorňuje jej na změny ve svém stavu voláním jeho metody update-lists.

Kód definující uživatelské rozhraní a volání update-lists z prostředí se vyhodnocuje jen v případě, že je kód načten v prostředí LispWorks. To zajišťuje použití direktivy #+lispworks před voláním příslušných funkcí.

²⁵http://www.lispworks.com/products/capi.html

3. Teoretická část

3.1. Expertní systém

Expertní systém je počítačový program, který usuzuje na základě znalostí z nějaké problémové domény za účelem vyřešení zadaného problému nebo poskytnutí odpovědi na otázku [2]. Problémovou doménou zde rozumíme množinu znalostí, omezenou na určitý okruh, který nás zajímá, s vyloučením všech ostatních, irelevantních znalostí [8]. Znalosti z problémové domény jsou reprezentovány jejím modelem²⁶. Expertní systém tedy pracuje s modelem zvolené problémové domény.

http://en.wikipedia.org/wiki/Expert_system#Applications poskytuje dobré příklady aplikací

K typickým problémům, řešeným pomocí expertních systému patří [2]

- plánování posloupnosti akcí vedoucích k zadanému cíli (např. plánování trasy ze znalosti dopravních spojů a dopravní situace), nevhodný příklad potřeba numerických výpočtů při výběru z více tras ne že by nešlo, ale není typickým příkladem
- interpretace dat (např. detekce nebezpečí z dat získaných z termografické kamery), analýza složení (vyhodnocení dat získaných metodami analytické chemie),
- diagnóza a plánování oprav poruch systému,
- konfugurace komplexních objektů (např. navržení serverového cloudu pro poskytnutí zadaných služeb).

V první kapitole své bakalářské práce [1] uvádím typické vlastnosti expertních systémů, jejich zařazení v rámci informatiky a umělé inteligence a jejich rozdíly oproti jiným typům programů, které daný problém mohou řešit. Stěžejní charakteristikou expertního systému je úplné oddělení reprezentace znalostí, nad kterými systém usuzuje, od samotného odvozovacího aparátu. Odvozovací aparát je tedy obecný a je schopen usuzovat nad jakoukoli problémovou doménou, jejíž model lze v expertním systému reprezentovat.

Jak vyplývá z uvedené definice, expertní systém je hotový program schopný odpovídat na dotazy, či řešit problémy v rámci zvolené problémové domény. Tento program můžeme vytvořit od základu v nějakém obecném programovacím jazyce.

²⁶http://en.wikipedia.org/wiki/Domain_model

To je ale poměrně složité a pokud nemáme specifické nároky, nevyplatí se to. Častěji použijeme existující nástroj či knihovnu pro tvorbu expertních systémů. Tento nástroj už obsahuje odvozovací aparát a definuje reprezentaci znalostí a dotazů a její syntax (viz sekce 3.2.). Poskytuje tedy tzv. prázdný expertní systém. Takovým nástrojem je i knihovna ExiL, která je přílohou této práce.

Zařazení expertního systému do procesu sestává z následujících fází:

- 1. sestavení modelu zvolené problémové domény,
- 2. výběr nástroje pro tvorbu expertních systémů podle typu domény a dotazů, které chceme být schopni zadávat,
- 3. reprezentace modelu problémové domény použitím syntaxe zvoleného nástroje.

Vytvořená reprezentace modelu problémové domény tvoří po načtení nástrojem pro tvorbu expertních systémů tzv. znalostní bázi výsledného expertního systému. Tomu pak můžeme zadávat dotazy buď přímo, použitím jeho syntaxe, nebo skrze nějaké uživatelské rozhraní. Je-li zvolený nástroj navržen jako knihovna, můžeme také vytvořit další program, který zadává znalosti do expertního systému a/nebo mu zadává dotazy a odpovědi na ně pak dále zpracovává.

Jednou z běžných vlastností expertních systémů je také schopnost vysvětlit, jak systém k řešení problému dospěl. To umožňuje evaluaci správnosti řešení a poskytuje tak zpětnou vazbu pro případnou opravu znalostní báze, zadaného cíle či dotazu, nebo odvozovacího aparátu (v případě vlastního návrhu expertního systému).

Expretní systém nelze použít k řešení jakéhokoli typu problému. To je dáno reprezentací znalostí v expertním systému a způsobem, jakým systém nad těmito znalostmi usuzuje. Vlastnosti znalostí, které lze v expertním systému reprezentovat, jejich reprezentace, způsoby zadávání cílů a dotazů i to, jak systém zadaných cílů dosahuje, je náplní následujících sekcí.

3.2. Reprezentace znalostí

Aby bylo možné pracovat se znalostmi v expertním systému, musí tyto splňovat několik vlastností:

- přesnost pro vyvození rozumných závěrů nemůže být znalost vágní (to neznamená, že nemůžeme vyjádřit nejistotu, i ta ale musí být definována přesně),
- relevance znalosti by se měly týkat pouze pojmů z problémové domény
- organizovanost znalosti by měly postihovat všechny potřebné spojitosti mezi pojmy (to zahrnuje například používání vždy stejného pojmu pro tutéž věc),

 uzavřenost - systém by pro vyvození závěrů neměl potřebovat žádné předchozí znalosti.

Systém nechápe význam znalostí, pracuje pouze s jejich reprezentací. Reprezentaci obecně chápeme jako množinu syntaktických a sémantických pravidel, které umožňují popsat nějaké entity. Reprezentaci entity pak jako výraz, který podle těchto pravidel popisuje danou entitu. Jazyk reprezentace je množina všech možných reprezentací entit. V expertních systémech jsou těmito entitami právě znalosti.

Syntax reprezentace je množina pravidel, která definují základní stavební bloky (atomy) jazyka reprezentace a jak jejich kombinací vytvářet výrazy tohoto jazyka, tedy reprezentace jednotlivých entit. Sémantika říká, jak jsou výrazy jazyka reprezentace interpretovány - jaký je jejich význam. Sémantika nám tedy dává zobrazení z reprezentace entity na reprezentovanou entitu. Sémantická pravidla jsou často rekurentní - přiřkneme význam atomům a poté jednotlivým strukturám, které vznikají jejich kombinací.

Aby byla reprezentace praktická, musí být

- jednoznačná není možné, aby měl jeden výraz jazyka reprezentace několik významů,
- expresivní reprezentace musí umožňovat vyjádření všech potřebných detailů (distinction) popisované entity
- srozumitelná význam výrazu by měl být snadno pochopitelný bez nutnosti chápat, jak je systémem zpracováván,
- stručná výrazy by mělo být snadné psát, neměly by být zbytečně mnohomluvné;
- reprezentaci musí být možno zpracovávat a ukládat v počítači.

Míra expresivity je často v protikladu snadného strojového zpracování, hledáme tedy kompromis, mezi těmito dvěma vlastnostmi.

Často používanými reprezentačními schematy jsou strukturované objekty, odvozovací pravidla a logické programy. Knihovna ExiL, stejně jako systém CLIPS používá prvních dvou. Typickou ukázkou třetího je jazyk Prolog²⁷.

Expertní systémy jsou systémy založené na pravidlech²⁸. Jako takové rozlišují dva základní typy znalostí - fakty a pravidla. Fakt je elementární "statická" znalost - vyjadřuje nějaké tvrzení z problémové domény, např. "obloha je jasná". Odvozovací pravidlo je pak elementární odvozovací znalostí a má formu implikace. Pravidlo vyjadřuje, jaké (jaká) tvrzení můžeme odvodit z platnosti jiných

²⁷http://en.wikipedia.org/wiki/Prolog

²⁸http://en.wikipedia.org/wiki/Rule-based_system

tvrzení, např. "pokud je obloha jasná, neprší". Pravidlo tedy sestává z *podmínek* ("obloha je jasná") a *důsledků* ("neprší").

Stav systému je tvořen množinou aktuálně platných tvrzení a reprezentován množinou reprezentací odpovídajících faktů. Tvrzení tedy platí, pokud je reprezentace příslušného faktu součástí stavu systému. Aplikace odvozovacího pravidla pak definuje přechod mezi dvěma stavy systému. Pravidlo je možné aplikovat, jsou-li splněny jeho podmínky. Při jeho aplikaci jsou pak vyhodnoceny jeho důsledky, na základě čehož je stav systému modifikován - reprezentace nějakých faktů jsou přidány do a/nebo odebrány z množiny, která stav reprezentuje.

Počáteční stav expertního systému spolu s množinou definovaných odvozovacích pravidel tvoří tzv. znalostní bázi systému. Pokud se může množina definovaných pravidel v průběhu práce se systémem měnit, zařazujeme ji také do stavu systému. Ten je pak reprezentován dvěma množinami - množinou reprezentací faktů (tzv. pracovní paměť) a množinou definovaných pravidel (tzv. produkční paměť).

Pojmy pracovní a produkční paměť nejsou příliš intuitivní. Jde o doslovný překlad v literatuře užívaných pojmů working memory a production memory. Nejde ve skutečnosti o paměťi, nýbrž o obsahy pomyslných pamětí. Pojmy "pracovní množina faktů" a "pracovní množina pravidel" by byly jistě výstižnější, bohužel ale také značně těžkopádné.

Různé expertní systémy se liší v reprezentaci faktů a pravidel. V různých expertních systémech tedy můžeme vyjádřit znalosti s různou mírou flexibility. Jednoduchým příkladem reprezentace faktů a pravidel je reprezentace expertního systému STRIPS²⁹. Atomy sytaxe této reprezentace jsou symboly. Ty reprezentují názvy jednotlivých objektů a relací z problémové domény. Fakty jsou pak ve tvaru <relace>(<argumenty oddělené čárkami>), např. At(robot,roomA).

Pravidla systému STRIPS (které jsou zde nazývány operátory) jsou pak tvořena třemi seznamy (množinami) faktů. První množina reprezentuje podmínky pro splnění pravidla, tedy tvrzení, která musí platit, aby bylo možné pravidlo aplikovat.

- reprezentace faktů a pravidel v STRIPS, odkaz na GPS (nebo až v inferenci?)
- strips umožňuje proměnné Atomy, postkondice jako jedna množina s případným not u odebíraných faktů
- CLIPS i EXIL speciální výraz vzoru v CLIPSU stavební blok není v jazyce reprezentace, v EXILu je i samostatný vzor reprezentací - reprezentuje cíl

²⁹http://en.wikipedia.org/wiki/STRIPS

- reprezentace pravidel v CLIPSU a EXILu syntax a sémantika (stavební bloky, význam - podmínky mají existenční charakter)
- EXIL cíle jako vzory (zpětná inference)
- dále pracovat s pojmem znalost (reprezentace je implicitní)
- reprezentace problému počáteční stav, přechody, koncový stav, příp. cíle (zpětná inference)
- reprezentace problému
 - problem solving involves reasoning about actions and states of the world (state = current knowledge = describes objects, their properties and relationonships)
 - problems can be formulated in terms of initial state, goal state and a set of operations, that can be employed in an attempt to transform one state into another
 - symbolické výpočty non-numeric computations, manipulation of symbolic representations

3.3. Základní principy

- rule-based systémy základní pojmy revisited s citacemi
- prohledávání prostoru stavů (stromy)
- combinatorial explosion \rightarrow heuristiky (strategie)

3.4. Dopředná a zpětná inference

- dopředné vs. zpětné řetězení
- zpětné means-ends analysis
- STRIPS x CLIPS

Expertní systémy rozdělujeme do dvou skupin podle toho, jakým způsobem nad zadanými znalostmi usuzují. **Expertní systém se dopředným řetězením** (inferencí) postupně vyvozuje závěry ze zadaných znalostí hledáním odvozovacích pravidel se splněnými podmínkami. **Expertní systém se zpětným řetězením** (inferencí) postupuje od zadaného cíle a hledá odvozovací pravidla, která vedou k jeho splnění. Jejich podmínky pak zpracovává jako dílčí cíle.

Požadovaný cíl či dotaz může být součástí znalostí předaných systému (typické pro systémy s dopřednou inferencí), nebo může být zadán samostatně (systémy se zpětnou inferencí). Může nás také zajímat množina všech závěrů, odvoditelných ze zadaných znalostí.

Zadáním cíle se systému dotazujeme, zda existuje posloupnost aplikace odvozovacích pravidel, vedoucí k jeho splnění. V případě nale

Buď konkrétní cíl. Cíl problému můžeme zadat systému jako dotaz (typické pro, ale ne omezené na, zpětné řetězení). Nebo nás může zajímat množina všech výsledků odvoditelných z báze. poskytnutí odpovědi na otázku - zda lze ze znalostní báze odvodit fakt daného tvaru (vzor), nalézt možné vazby proměnných

3.5. Interpretace programu

- interpretace výstupu programu
- plánování akcí
- hledání odpovědí
- dokazování vyplývání sémantika podmínek

Reference

- [1] Kaláb, J.: Implementace expertního systému s dopředným řetězením. Bakalářská práce, Universita Palackého v Olomouci, 2010.
- [2] Jackson, P.: Introduction to Expert Systems. Addison Wesley, 1998, ISBN 0-201-87686-8.
- [3] Norvig, P.: Paradigms of Artificial Intelligence Programming: Case Studies in Common Lisp. Morgan Kaufmann Publishers, 1991, ISBN 1-55860-191-0.
- [4] Doorenbos, R. B.: Production Matching for Large Learning Systems. Dizertační práce, Carnegie Mellon University, 1995. http://reports-archive.adm.cs.cmu.edu/anon/1995/CMU-CS-95-113.pdf
- [5] CLIPS: Tool for Building Expert Systems. 2013. http://clipsrules.sourceforge.net/OnlineDocs.html
- [6] Expert system Wikipedia, The Free Encyklopedia. 2013. http://en.wikipedia.org/wiki/Expert_system
- [7] Rete algorithm Wikipedia, The Free Encyklopedia. 2013. http://en.wikipedia.org/wiki/Rete_algorithm
- [8] Problem domain Wikipedia, The Free Encyklopedia. 2013. http://en.wikipedia.org/wiki/Problem_domain